

O Efeito do Escalonamento do Meta-Alvo na Performance de Sistemas de Meta-Aprendizagem para Seleção de Algoritmos

Lael de Lima Santa Rosa

Instituto de Computação
Universidade Federal de Alagoas (UFAL)

Junho de 2026

`llsr@ic.ufal.br`

O Problema da Seleção de Algoritmos

- Testar todos os algoritmos para um novo dataset é inviável.
- **Meta-aprendizagem** resolve isso associando características do dataset (*meta-features*) ao desempenho de algoritmos (*meta-alvo*).

Inspiração da Literatura

- Amorim et al. (2022) provaram que o **escalonamento de atributos de entrada importa** no nível base.
- **Lacuna:** E o escalonamento do **meta-alvo** (variável dependente) na regressão meta?

Nível Meta

Meta-Features (X)
[Pré-processado]

↓ Regressão Meta

Meta-Alvo (Y)
[Geralmente Bruto]

Figura: Foco no meta-alvo.

O Problema e as Hipóteses

Pergunta de Pesquisa Central

O escalonamento do meta-alvo em sistemas de meta-aprendizagem produz diferenças relevantes de performance? Existe uma recomendação geral que funcione para qualquer meta-modelo?

Hipótese 1 (H1)

Sensibilidade: Meta-modelos sensíveis (SVR, MLP) apresentarão diferenças significativas entre as técnicas.


Hipótese 2 (H2)

Invariância: Meta-modelos baseados em árvores (Random Forest) serão insensíveis às escalas lineares.

Hipótese 3 (H3)

Não-universalidade: Não existirá uma técnica de escalonamento que seja a melhor para todos os casos.

A Proposta e o Pipeline de Trabalho



Prevenção de Vazamento (Data Leakage)

O ajustador S é computado exclusivamente no conjunto de treino. A inversão S^{-1} garante que todas as métricas sejam medidas na escala original do F1-score.

Técnicas de Escalonamento

- ❶ **Baseline (Sem ajuste):** $\tilde{y} = y$
- ❷ **StandardScaler (Z-score):** $\tilde{y} = \frac{y - \mu}{\sigma}$
- ❸ **MinMaxScaler:** $\tilde{y} = \frac{y - y_{\min}}{y_{\max} - y_{\min}}$
- ❹ **RobustScaler:** $\tilde{y} = \frac{y - \text{mediana}}{\text{IQR}}$ (resistente a outliers)
- ❺ **QuantileTransformer:** Não-linear, força a distribuição para normal ($\tilde{y} = \Phi^{-1}(\text{rank})$)

Os métodos 1-4 são monotônicos; o 5 pode alterar ranks.

Métricas de Avaliação

- **MAE:** Erro numérico absoluto na escala original do F1-score.
- **Spearman (ρ_s):** Correlação entre a ordenação prevista e real dos algoritmos base.
- **Acc@1:** Frequência com que o algoritmo recomendado como melhor foi de fato o melhor.

Quatro Experimentos Progressivos

- **Exp. 1:** 50 datasets (4 reais, 46 sintéticos), 8 features manuais.
- **Exp. 2:** 144 datasets reais (OpenML), 8 features manuais.
- **Exp. 3:** 200 datasets reais (OpenML), 8 features manuais.
- **Exp. 4:** 200 datasets reais, 78 meta-features estruturadas (PyMFE).

Validação Cruzada e Pré-processamento

- Nível base: 5-Fold Stratified CV.
- Nível meta: 5-Fold CV (divisão por datasets).
- **Entrada (X):** Padronizada com `StandardScaler` ajustado no fold de treino.

Componentes de Aprendizado

Algoritmos Base (para obter o alvo Y):

- KNN ($k = 5$), Árvore de Decisão, Random Forest (100), Naive Bayes e SVM.

Meta-Modelos (Regressores Multi-Saída):

- Ridge ($\alpha = 1.0$), SVR (RBF), Random Forest (100), MLP (16, 8).

Resultados: Distribuição do Meta-Alvo

Caracterização do Meta-Alvo (F1-macro)

- Calculado sobre os 200 datasets reais (OpenML).
- **Alta Dispersão:** Desvios padrões significativos (≈ 0.20), com F1-score variando de 0.0 a 1.0.
- Presença de tarefas muito fáceis e tarefas muito difíceis.
- **Consequência:** Dificuldade para algoritmos de gradiente sem normalização.

Tabela: Estatísticas do meta-alvo (200 datasets)

Algoritmo	Média	Desv. P.	Med.	Máx.
KNN	0,654	0,197	0,643	1,000
Dec. Tree	0,720	0,185	0,702	1,000
Rand. Forest	0,734	0,191	0,735	1,000
Gaussian NB	0,643	0,210	0,648	1,000
SVM	0,589	0,239	0,555	1,000

Comparativo: Meta-features Manuais (Exp. 3) vs. PyMFE (Exp. 4)

Comparativo direto entre as melhores configurações obtidas com 8 features manuais e 78 features do PyMFE.


Tabela: Impacto da Riqueza de Meta-features (200 datasets)

Meta-Modelo	Cenário	Scaler Recomendado	MAE	Spearman
Ridge	Exp. 3 (8 Features)	Baseline / Lineares	0,1469	0,4625
	Exp. 4 (78 PyMFE)	Baseline / Lineares	0,1007 (-31%)	0,4966
SVR	Exp. 3 (8 Features)	RobustScaler	0,1238	0,5238
	Exp. 4 (78 PyMFE)	Robust / Standard	0,0884 (-28%)	0,5982
Random Forest	Exp. 3 (8 Features)	MinMaxScaler	0,1143	0,5543
	Exp. 4 (78 PyMFE)	MinMaxScaler	0,0845 (-26%)	0,6157
MLP	Exp. 3 (8 Features)	StandardScaler	0,1306	0,4308
	Exp. 4 (78 PyMFE)	StandardScaler	0,1165 (-11%)	0,3875

Obs: A redução no erro absoluto (MAE) varia de 11% a 31% com a inclusão de meta-features ricas (PyMFE).

Resultados: Impacto Geral e Comparativo (Manuais vs. PyMFE)

Comparativo Sobreposto: Meta-features Manuais (Exp 3, Translúcido) vs. PyMFE (Exp 4, Sólido)



O Impacto da Riqueza de Meta-features

A transição das 8 features manuais (translúcido) para as 78 features do PyMFE (sólido) reduziu o MAE e aumentou a Spearman em todos os meta-modelos.

Resultados: O Colapso e Recuperação do MLP

Colapso no Baseline

- Sem centralização de escala, o MLP **colapsa** em dados reais.
- A Spearman cai a **0.080** e Acc@1 fica em **21.2%** (pior que o acaso).
- Causa: Gradientes instáveis e saturação das ativações devido à alta dispersão.

Recuperação pelos Scalers

- **Standard/RobustScaler** evitam o colapso: MAE reduz em **36.3%** e Spearman sobe para **0.38 - 0.43**.

Tabela: Desempenho do MLP nos Experimentos

Cenário	Scaler	MAE	Spearman	Acc@1
Exp. 1	Baseline	0,147	0,274	0,320
	Robust	0,071	0,588	0,440
Exp. 2	Baseline	0,179	0,034	0,125
	Robust	0,118	0,453	0,438
Exp. 3	Baseline	0,174	0,167	0,207
	Standard	0,131	0,431	0,374
Exp. 4	Baseline	0,183	0,080	0,212
	Robust	0,122	0,354	0,359

Resultados: Ridge, SVR e Random Forest

Ridge (Linear)

- **Matematicamente invariante** às transformações lineares no alvo.
- Resultados idênticos para Standard, Min-Max e Robust.
- O erro absoluto piora com o QuantileTransformer ($\Delta = +0,0145$).

SVR (Kernel RBF)

- Apresenta **melhora altamente significativa** ($p < 10^{-10}$) com escalonamento.
- O RobustScaler minimizou o MAE para **0.0884**.
- O StandardScaler maximizou a Spearman (**0.5982**) e o Acc@1 (**49.5%**).

Random Forest

- **Invariante a escalas lineares:** MAE variou residualmente (≈ 0.0015) sem diferença estatística ($p = 0.333$).
- O MinMaxScaler apresentou o melhor resultado global ($\rho_s = 0.6157$, Acc@1 = **51.5%**).

Validação Estatística: Teste de Friedman

O teste de Friedman avalia se há diferença estatisticamente significativa no MAE ao variarmos as técnicas de escalonamento ($\alpha = 0,05$).

Tabela: Resultados do Teste de Friedman (Exp. 2, 3 e 4)

Experimento	Meta-Modelo	χ^2	p-value	Decisão
Exp. 2 (144 ds)	Ridge	3,04	0,551	Não significativo
	SVR	8,37	0,079	Não significativo
	Random Forest	5,41	0,248	Não significativo
	MLP	148,72	$3,8 \times 10^{-31}$	Significativo
Exp. 3 (200 ds)	Ridge	1,61	0,807	Não significativo
	SVR	3,41	0,491	Não significativo
	Random Forest	0,34	0,987	Não significativo
	MLP	110,71	$5,1 \times 10^{-23}$	Significativo
Exp. 4 (PyMFE)	Ridge	22,38	$1,7 \times 10^{-4}$	Significativo
	SVR	53,92	$5,5 \times 10^{-11}$	Significativo
	Random Forest	4,58	0,333	Não significativo
	MLP	278,02	$5,9 \times 10^{-59}$	Significativo

Evolução da Significância

- **MLP:** Único modelo com sensibilidade estatística em todos os cenários reais (Exp. 2, 3 e 4).
- **Exp. 2 e 3:** Baixo volume de features manuais impediu a detecção de significância no SVR e Ridge.
- **Exp. 4 (PyMFE):** O enriquecimento de entrada deu maior poder estatístico, revelando a sensibilidade do **SVR** e **Ridge**.
- **Random Forest:** Consistente e insensível em todos os cenários.

Discussão: O Paradoxo do QuantileTransformer

Efeito de Distorção de Rank

- O QT mapeia dados de forma não-linear para forçar normalidade.
- Embora minimize o MAE em alguns casos, ele **distorce a ordem relativa** dos algoritmos base.
- **Impacto:** Queda generalizada na acurácia Acc@1 para Ridge, SVR e RF.

O Caso Particular do MLP

- No Experimento 4 (PyMFE), o QT foi o escalonador que obteve a **maior Spearman** para o MLP ($\rho_s = 0,4355$).
- **Explicação:** Em espaços densos de features, a normalização de alvo por quantis pode favorecer a correlação de rank do MLP.

Recomendação Prática

Evitar o uso do QuantileTransformer se o objetivo do sistema for recomendar o melhor algoritmo (Acc@1).

Conclusões e Recomendações

- **Hipóteses Validadas:** A sensibilidade depende fortemente da arquitetura. Árvores são robustas; gradientes/kernel são sensíveis.
- **Riqueza de Features:** O uso do PyMFE foi crucial para reduzir erros absolutos.
- **Recomendação Prática:** Usar **RobustScaler** como padrão seguro para modelos sensíveis.

Tabela: Guia de Recomendação de Escalonamento do Meta-Alvo

Meta-Modelo	Objetivo do Sistema	Escalonador Recomendado
Random Forest	Qualquer Objetivo	Baseline (Sem) ou MinMaxScaler
SVR	Maximizar Recomendação (Acc@1)	StandardScaler
	Minimizar Erro Absoluto (MAE)	RobustScaler
MLP	Maximizar Recomendação (Acc@1)	RobustScaler
	Minimizar Erro Absoluto (MAE)	StandardScaler
Todos	Evitar Deformar Rankings	X Evitar QuantileTransformer para Acc@1
MLP	Evitar Erros Numéricos	X Evitar MinMaxScaler e Baseline