



Meta-aprendizagem

Introdução à meta-aprendizagem

Prof. Lucas Amorim - lucas@ic.ufal.br

1

Sumário

- Conceitos básicos
- Tipos de problemas
- Arquitetura básica de sistemas de meta-aprendizagem e AutoML
- Exemplo
- Exercício



2

Conceitos Básicos

Papel da aprendizagem de máquina

- Ambientes modernos geram grandes volumes de dados heterogêneos
- Os dados permitem a descoberta de padrões, agrupamentos e suporte à tomada de decisão
- Aplicações incluem detecção de fraudes, descoberta de fármacos e modelagem científica
- O Aprendizado de Máquina fornece métodos para modelar fenômenos complexos a partir de dados
- Diferentes algoritmos baseiam-se em diferentes suposições e vieses indutivos




3

Conceitos Básicos

Papel da meta-aprendizagem

- Não existe um único algoritmo que apresente o melhor desempenho para todos os conjuntos de dados
- A seleção de algoritmos é, por si só, um problema de aprendizado
- O metalearning concentra-se no aprendizado entre tarefas
- Utiliza experiências obtidas em episódios de aprendizado anteriores
- Melhora a eficiência, a robustez e a confiabilidade dos sistemas de aprendizado de máquina



4

Conceitos Básicos

Definições e Escopo

Meta-aprendizagem é o estudo de métodos que exploraram meta-conhecimento para obter modelos e soluções eficientes adaptando processos de aprendizagem de máquina. (P. Brazdil et al. 2022)

- O meta-conhecimento inclui qualquer tipo de informação sobre conjuntos de dados (tarefas) anteriores, os algoritmos e pipelines aplicados a eles e os respectivos resultados de desempenho.
- O meta-conhecimento também pode incorporar conhecimento obtido durante a busca na tarefa atual.

P. Brazdil et al., Metalearning - Applications to automated machine learning and data mining. Springer. 2022.

5

Conceitos Básicos

Definições e Escopo

- Qual é a diferença entre meta-aprendizagem e AutoML (Automated Machine Learning)?

AutoML refere-se a todos os aspectos de automatização do processo de aprendizagem de máquina, indo a além da seleção do modelo, otimização de hiperparâmetros e busca por modelo, [...] (Guyon et al. 2015).

- Meta-aprendizagem está intimamente relacionada ao AutoML e frequentemente integrado a esses sistemas.
- O foco da disciplina ao estudar AutoML será em sistemas que utilizem meta-aprendizagem.

Guyon, I. et al. Design of the 2015 ChaLearn AutoML challenge. In 2015 IJCNN. IEEE. 2015.

6

Tipos de Problemas

Tipos de problemas onde se aplica meta-aprendizagem:

- AS - Seleção de Algoritmos
- HPO - Otimização de Hiperparâmetros
- CASH - Combined algorithm selection and hyperparameter optimization (*Seleção de algoritmo combinada à otimização de hiperparâmetros*).
- Síntese de pipeline (fluxos de trabalhos)
- Busca ou síntese de arquitetura
- Aprendizagem few-shot

7

Tipos de Problemas

AS - Seleção de Algoritmos

- Dados um conjunto de algoritmos e um dataset alvo, escolher o algoritmo mais apropriado para otimizar alguma métrica (ex. acurácia de predição).
- Define-se o problema sobre um conjunto **discreto** de algoritmos.




Exemplo: de Amorim, L. B. V. et al. (2024). Meta-Scaler: A Meta-Learning Framework for the Selection of Scaling Techniques. *IEEE Trans. on Neural Networks and Learning Systems*.

8

Tipos de Problemas

HPO - Otimização de Hiperparâmetros

- Dados um algoritmo e um dataset alvo, determinar a configuração de hiperparâmetros mais apropriada para otimizar alguma métrica (ex. acurácia de predição).
- Define-se o problema sobre um espaço de configurações **contínuo**.




Exemplo: Gomes, T. A. F., et al. (2012). Combining meta-learning and search techniques to select parameters for support vector machines. *Neurocomputing*, 75(1), 3–13.

9

Tipos de Problemas

CASH - Combined algorithm selection and hyperparameter optimization

- Dados um conjunto de algoritmos, e um dataset alvo, determinar que algoritmo utilizar e a configuração de hiperparâmetros mais apropriada para otimizar alguma métrica (ex. acurácia de predição).




10

Tipos de Problemas

Workflow (pipeline) synthesis

- Dados um conjunto de algoritmos, e um dataset alvo, projetar um pipeline consistindo de um ou mais algoritmos, cada um com seus hiperparâmetros, para modelar o dataset alvo. A inclusão de cada algoritmo no pipeline pode ser vista, de maneira isolada, como um problema CASH.



11

Tipos de Problemas

Busca ou síntese de arquitetura

- Pode ser visto como uma generalização do tipo de problema anterior. Os elementos não precisam estar em sequência como nos pipelines. Ex.: Design de arquitetura de redes neurais.




12

Tipos de Problemas

Aprendizagem Few-shot

- Dados um dataset alvo com **poucos exemplos** e vários datasets anteriores que são similares, mas incluem muitos exemplos, obter um modelo pré-treinado nos datasets anteriores e fazer o ajuste fino para que performe bem no dataset alvo.



13

Arquitetura básica de sistemas de meta-aprendizagem e AutoML

- O Problema da Seleção de Algoritmo (ASP) foi formulado por John R. Rice (1976).
 - É possível relacionar a performance de algoritmos a características do conjunto de datasets.
 - Características dos dados costumam ser bons preditores de performance de algoritmos.



14

Arquitetura básica de sistemas de meta-aprendizagem e AutoML




Fig. 1.2: Using a meta-level model to predict the best algorithm

15

Arquitetura básica de sistemas de meta-aprendizagem e AutoML

Exemplo

Tudo que precisamos é meta-conhecimento!

Passo 1: Obtenha um conjunto de datasets de treinamento



Passo 2: Avalie as performances de um conjunto algoritmos nesses datasets

DS	SVM_1	SVM_2	DT	RF	KNN
DS1	0.8	0.9	0.75	0.82	0.7
DS2	0.7	0.6	0.8	0.83	0.75
DS3	0.55	0.66	0.65	0.68	0.61
DS4	0.9	0.91	0.92	0.9	0.95
DS5	0.88	0.87	0.80	0.85	0.82

Qual é o alvo?

Quais são as variáveis preditivas (atributos) ?

16

Arquitetura básica de sistemas de meta-aprendizagem e AutoML



Exemplo

Tudo que precisamos é meta-conhecimento!

Passo 3: Extraia meta-características de todos os datasets

Meta-features

- Number of instances
- Number of features
- Mean of stddevs
- Mean of means
- Mean of medians
- Mean of ranges
- Entropy
- Skewness
- Kurtosis
- Ratio instances/features
- Performance of a simple DT
- Etc...



DS	MF1	MF2	MF3	MF4	MF5
DS1	500	30	0.3	3.1	2.9
DS2	10000	10	0.31	3.1	3.5
DS3	760	25	0.45	4.6	4.2
DS4	1350	13	0.03	0.9	0.95
DS5	158	35	0.8	0.85	0.82

17

Arquitetura básica de sistemas de meta-aprendizagem e AutoML



Exemplo

Tudo que precisamos é meta-conhecimento!

Passo 4: Combine as meta-features e as performances

DS	MF1	MF2	MF3	MF4	MF5	SVM	SVM_2	DT	RF	KNN
DS1	500	30	0.3	3.1	2.9	0.8	0.9	0.75	0.82	0.7
DS2	10000	10	0.31	3.1	3.5	0.7	0.6	0.8	0.83	0.75
DS3	760	25	0.45	4.6	4.2	0.55	0.66	0.65	0.68	0.61
DS4	1350	13	0.03	0.9	0.95	0.9	0.91	0.92	0.9	0.95
DS5	158	35	0.8	0.85	0.82	0.88	0.87	0.80	0.85	0.82

+

Meta-dataset (seu meta-conhecimento)

18

Arquitetura básica de sistemas de meta-aprendizagem e AutoML



Exemplo

Tudo que precisamos é meta-conhecimento!

Passo 5: Treine o meta-modelo

DS	MF1	MF2	MF3	MF4	MF5	SVM_1	SVM_2	DT	RF	KNN
DS1	500	30	0.3	3.1	2.9	0.8	0.9	0.75	0.82	0.7
DS2	10000	10	0.31	3.1	3.5	0.7	0.6	0.8	0.83	0.75
DS3	760	25	0.45	4.6	4.2	0.55	0.66	0.65	0.68	0.61
DS4	1350	13	0.03	0.9	0.95	0.9	0.91	0.92	0.9	0.95
DS5	158	35	0.8	0.85	0.82	0.88	0.87	0.80	0.85	0.82



Meta-model

Regressor Multi-output → Muito complexo?

19

Arquitetura básica de sistemas de meta-aprendizagem e AutoML



Exemplo

Você pode simplificar o meta-problema!

Passo 4.5: Transforme as variáveis alvo

DS	MF1	MF2	MF3	MF4	MF5	Best
DS1	500	30	0.3	3.1	2.9	SVM_2
DS2	10000	10	0.31	3.1	3.5	RF
DS3	760	25	0.45	4.6	4.2	RF
DS4	1350	13	0.03	0.9	0.95	KNN
DS5	158	35	0.8	0.85	0.82	SVM_1



Passo 5: Treine o classificador multi-classe simples.


20

Arquitetura básica de sistemas de meta-aprendizagem e AutoML



Exemplo

Passo 6: Aplique (deploy) seu meta-modelo na prática



21

Exemplo



Exemplo 3

<https://github.com/amorimlb/Meta-aprendizagem-2026.1-code>

22

Exercício



Acesse o código do Exemplo 3 no repositório da disciplina no GitHub e realize mudanças com o objetivo de melhorar a performance média de nível base em termos de acurácia. Dica: busque primeiramente melhorar a performance em nível meta, acrescentando instâncias, pré-processamento do meta-dataset e alterando o meta-modelo. Gere uma tabela com os resultados obtidos com as diferentes versões testadas.

<https://github.com/amorimlb/Meta-aprendizagem-2026.1-code>

23