



Meta-aprendizagem

Abordagens de meta-aprendizagem para seleção de algoritmos - explorando rankings

Prof. Lucas Amorim - lucas@ic.ufal.br

1

Sumário

- Introdução
- Diferentes formas de recomendação
- Criando ranking de modelos para seleção de algoritmo (AS)
- Usando uma métrica combinada (acurácia e tempo de execução)
- Exercício



2

Introdução



- Na aula passada vimos um exemplo de sistema de meta-aprendizagem capaz de recomendar um único algoritmo para cada dataset (Exemplo 3).
- Para treinar o meta-modelo para recomendar um único algoritmo, precisamos reduzir a informação sobre performances que tínhamos para uma única classe: o melhor algoritmo (Best).
- Com isso simplificamos o problema, no entanto surgem novos problemas:
 - Perdemos a informação sobre empates.
 - Geramos ruído no aprendizado do meta-modelo ao arbitrariamente selecionar um de vários algoritmos similares como o melhor.
 - Perdemos a informação sobre algoritmos potencialmente tão bons quanto (ou até melhores) que o primeiro lugar.
- Há outras possibilidades sobre como definir o alvo, i.e. a forma de recomendação.

3

Diferentes formas de recomendação



- Antes de detalhar MtL com rankings, vejamos quais são as diferentes formas de recomendação:

1. Melhor algoritmo de um conjunto;
2. Subconjunto dos top n algoritmos;
3. Ranking linear;
4. Ranking quasi-linear (fraco);
5. Ranking incompleto.

Table 2.1: Examples of different forms of recommendation

1. Best in a set	a_3					
2. Subset	$\{a_3, a_1, a_5\}$					
3. Linear and complete ranking	Rank					
	1	2	3	4	5	6
4. Quasi-linear and complete ranking	a_3	a_1	a_5	a_6	a_4	a_2
5. Linear and incomplete ranking	a_3	a_1	a_5	a_6		

4

Diferentes formas de recomendação




Fig. 2.1: Representation of rankings using Hasse diagrams: (a) complete linear ranking; (b) complete quasi-linear ranking; (c) incomplete linear ranking; (d) incomplete quasi-linear ranking

5

Diferentes formas de recomendação



Melhor algoritmo de um conjunto

- Esta primeira forma consiste em identificar o algoritmo que se espera que obtenha a melhor performance no conjunto de algoritmos de nível base.
- Note que isto é formalmente um ranking de tamanho 1.
- Um sistema de simples (sem usar aprendizado) pode ser construído para recomendar o algoritmo mais frequente entre os conjuntos de dados conhecidos.
- Como esta estratégia não usa busca. Mesmo utilizando aprendizado, há sempre a chance de o algoritmo recomendado não ser de fato o melhor em cada caso.

6

Diferentes formas de recomendação



Subconjunto dos top n algoritmos

- Estes métodos recomendam um subconjunto (normalmente pequeno) de algoritmos para os quais se espera boa performance no dado problema (dataset).
- A ideia é fornecer um subconjunto bem menor do que o conjunto original de algoritmos em que exista uma probabilidade alta de o melhor algoritmo de fato estar neste subconjunto.
- O usuário do sistema de recomendação pode aplicar uma estratégia de busca neste subconjunto.
- Um sistema de simples (sem usar aprendizado) pode ser construído para recomendar os top n algoritmos considerando o ranking médio.


7

Diferentes formas de recomendação



Ranking linear

- O sistema também pode recomendar um ranking de algoritmos.
- A ideia é que o usuário possa realizar uma busca seguindo a ordem do ranking.
- É chamado de ranking linear porque os ranks são diferentes para todos os algoritmos.
- É um ranking completo porque todos os algoritmos têm seu rank definido.
- Desvantagem: não é possível representar casos de empate.




8

Diferentes formas de recomendação

Ranking quasi-linear

- Sempre que dois ou mais algoritmos empatam, o ranking quasi-linear pode ser utilizado.
- Estes rankings representam situações em que os dados não permitem distinguir a performance relativa dos algoritmos em um dataset.
- O problema é resolvido assinalando o mesmo rank aos algoritmos que estão empatados.
- Um sistema de meta-aprendizagem que recomenda rankings nessa forma foi proposto por Brazdil et al. (2001).




Brazdil, P., Soares, C., and Pereira, R. (2001). Reducing rankings of classifiers by eliminating redundant cases. In Brazdil, P. and Jorge, A., editors, Proceedings of the 10th Portuguese Conference on Artificial Intelligence (EPIA2001). Springer.

9

Diferentes formas de recomendação

Ranking incompleto

- Tanto o ranking linear como o quasi-linear podem ser incompletos.
- Alguns algoritmos podem não ter sido avaliados no dataset por motivos diversos: Erros, custo computacional elevado, dificuldades técnicas, etc.
- Outra situação é quando novos algoritmos são desenvolvidos e precisam ser adicionados ao conjunto existente. A execução nos datasets pode ser gradual.
- Os metadados não precisam estar completos.



10

Diferentes formas de recomendação

Busca pelo melhor algoritmo dentro de um orçamento

- Rankings são adequados para recomendação pois:
 - O sistema de meta-aprendizagem pode ser desenvolvido sem qualquer informação sobre quantos algoritmos base o usuário testará no dataset.
 - Este número depende dos recursos computacionais disponíveis (orçamento) e da importância de obter boa performance (ex.: acurácia) no dataset.
- Se o tempo for o fator crítico, somente poucas alternativas devem ser selecionadas.
- Se o fator crítico é a acurácia, então mais algoritmos dentre os recomendados devem ser examinados.

11

Diferentes formas de recomendação

Criando ranking de modelos para seleção de algoritmo (AS)

- A intuição por trás de usar métodos de ranking é que se o objetivo é identificar o algoritmo com a melhor performance, é mais importante saber as **performances relativas** do que as performances absolutas dos algoritmos.
- Para resolver este problema com o uso de meta-aprendizagem, precisamos usar o mesmo método visto anteriormente no Exemplo 3, composto de duas principais fases: (1) Fase de construção do modelo e (2) fase de recomendação.
 1. Fase de construção do meta-modelo: Coleta-se os meta-dados (performance e meta-características), treina-se o meta-modelo.
 2. Usa-se o modelo treinado para recomendar algoritmo(s) para um dataset alvo.

12

Diferentes formas de recomendação

Criando ranking de modelos para seleção de algoritmo (AS)

- Desafio: Como treinar um modelo para recomendar rankings?
- Um modelo é treinado de acordo com o meta-dataset que é fornecido. A recomendação será no mesmo formato do meta-alvo.
- Duas abordagens:
 - Predizer performances, converter em rankings: Manter a matriz de performances original como meta-alvo, treinar o meta-modelo como um regressor de múltiplas saídas para prever as performances, em seguida, converter as performances previstas em rankings.
 - Converter performances em rankings, prever rankings: Converter a matriz de performances em uma matriz de rankings e utilizar os rankings como meta alvo. Treinar o meta-modelo como um regressor de múltiplas saídas para prever diretamente o ranking.
- Qual das duas abordagens deve funcionar melhor?

13

Diferentes formas de recomendação

Criando ranking de modelos para seleção de algoritmo (AS)

Meta-alvo da abordagem 1

DS	SVM_1	SVM_2	DT	RF	KNN
DS1	0.8	0.9	0.75	0.82	0.7
DS2	0.7	0.6	0.8	0.83	0.75
DS3	0.55	0.66	0.65	0.68	0.61
DS4	0.9	0.91	0.92	0.9	0.95
DS5	0.88	0.87	0.80	0.85	0.82

Meta-alvo da abordagem 2

DS	SVM_1	SVM_2	DT	RF	KNN
DS1	3	1	4	2	5
DS2	4	5	2	1	3
DS3	5	2	3	1	4
DS4	4.5	3	2	4.5	1
DS5	1	2	5	3	4

- Qual das duas abordagens deve funcionar melhor?

14

Diferentes formas de recomendação

Criando ranking de modelos para seleção de algoritmo (AS)

- Uma abordagem híbrida foi proposta por Fehring et al. (2022)
- HARRIS: Hybrid ranking and regression forests for algorithm selection.
- Combina as vantagens das duas abordagens e busca mitigar as desvantagens de cada uma.
- Um modelo de floresta em que cada árvore é criada baseada em splits otimizados de acordo com uma função de custo que considera o erro da regressão do ranking e das performances.



Fehring, L., Hanselle, J. M., and Tornede, A. Harris: Hybrid ranking and regression forests for algorithm selection. In NeurIPS 2022 Workshop on Meta-Learning (MetaLearn 2022), 2022.

15

Diferentes formas de recomendação

Usando uma métrica combinada (acurácia e tempo de execução)

- Rankings podem ser baseados em qualquer medida de performance que queiramos considerar.
- Tradicionalmente busca-se recomendar algoritmos com maior qualidade de predição (acurácia, F1, AUC, etc.)
- Medidas que combinam a qualidade de predição com o tempo de execução vem são empregadas para garantir uma recomendação que leve em conta o custo do algoritmo.

16

Diferentes formas de recomendação

Usando uma métrica combinada (acurácia e tempo de execução)

$$A3R'_{a_j} = \frac{P_{a_j}^{d_j}}{(T_{a_j}^{d_j})^Q}$$

- van Rijn et al. (2015) propôs a medida $A3R$.
- Onde $P_{a_j}^{d_j}$ representa a performance do algoritmo a_j no dataset d_i e $T_{a_j}^{d_j}$ representa o tempo de execução correspondente.
- O termo Q controla o balanço nas importâncias do tempo e da qualidade de predição.
- Tipicamente, é dado um valor baixo a Q , como 1/64. Para evitar que o tempo de execução (que varia bastante) domine a equação.

van Rijn, J. N., Abdulrahman, S., Brazdil, P., and Vanschoren, J. (2015). Fast algorithm selection using learning curves. In International Symposium on Intelligent Data Analysis XIV, pages 298–309.



Exercício

Acesse o código do Exemplo 3 no repositório da disciplina no GitHub e realize alterações para testar as duas abordagens de recomendação de algoritmos por ranking vistas nesta aula. Compare os resultados dessas duas abordagens e com o método "best algorithm" já implementado no Exemplo 3. Gere tabelas, gráficos e testes de hipóteses. Crie, no notebook, células textuais apresentando e discutindo os resultados. Envie na tarefa o link para o Google Colab.

<https://github.com/amorimlb/Meta-aprendizagem-2026.1-code>