



Meta-aprendizagem

Características de datasets (meta-atributos)

Prof. Lucas Amorim - lucas@ic.ufal.br

1



Sumário

- Introdução
- Meta-características usadas em tarefas de classificação
- Meta-características usadas em tarefas de regressão
- Meta-características usadas em tarefas de séries temporais
- Meta-características usadas em tarefas de agrupamento
- Derivando novas meta-features
- Seleção de meta-features
- Estudo da importância das meta-features no domínio de classificação
- Questões de representação específicas a algoritmos
- Similaridade entre datasets

2



Introdução

- Essencialmente, meta-aprendizagem busca aprender o relacionamento entre a **performance de algoritmos** e **características dos dados**.
- Chamamos as características dos dados de meta-características ou **meta-atributos**.
- **Meta-atributos** são medidas padronizadas que codificam numericamente as características de um conjunto de dados.
- É necessário identificar quais características são boas preditoras da performance relativa de algoritmos e então computar seus valores a partir dos dados.
- Essas meta-atributos podem ser usadas para prever a performance de algoritmos em diferentes conjuntos de dados.

3



Introdução

Características de boas meta-atributos:

- Poder discriminativo: Precisam ter relacionamento intrínseco com o meta-alvo, contendo informação que ajude a distinguir o seu valor. Ex.: distinguir o melhor algoritmo em nível base.
- Uniformemente computável: Todas as meta-atributos devem ser computáveis independentemente do dataset. Garantindo que qualquer dataset possa ser representado por um mesmo padrão.
- Baixo custo computacional: As meta-atributos não podem ter uma complexidade de extração tão alta que torne o processo de meta-aprendizagem mais complexo do que simplesmente testar todos os algoritmos base no dataset.
- Dimensionalidade: O número de meta-atributos não deve ser tão grande comparado à quantidade disponível de meta-dados, de forma a evitar sobreajustamento.

4

Introdução



Caracterização de algoritmos

- Embora nosso foco seja em meta-atributos que caracterizam datasets, caracterização de algoritmos também pode ser útil.
- Em Hilario e Kalousis (2001), propõe-se o uso de informações sobre:
 - Tipo de representação: O tipo de dados com os quais o algoritmo é capaz de lidar.
 - Abordagem: estratégia de aprendizagem, tal como lazy/eager.
 - Resiliência: Sensibilidade a atributos irrelevantes, com base em estudos experimentais.
 - Praticidade: Facilidade na manipulação de parâmetros.

Hilario, M. and Kalousis, A. (2001). Fusion of meta-knowledge and meta-data for case-based model selection. In Siebes, A. and De Raedt, L., editors, Proceedings of the Fifth European Conference on Principles and Practice of Knowledge Discovery in Databases (PKDD01). Springer.

5

Introdução



Caracterização específica aos dados e à tarefa

- O conjunto de meta-atributos adequado para cada problema varia bastante.
- O melhor conjunto de meta-atributos para um dado problema de meta-aprendizagem depende da tarefa, dos datasets e dos algoritmos.
- Veremos detalhes sobre quais características dos dados são utilizadas nas tarefas de aprendizagem de máquina mais comuns: classificação, regressão, previsão de séries temporais, e agrupamento.
- Desenvolvimento de meta-atributos úteis é essencial para o sucesso dos sistemas de meta-aprendizagem. Normalmente abordado por meio de engenharia de (meta-)atributos. Veremos detalhes também de outras abordagens.

6

Meta-características usadas em tarefas de classificação



Tipos de meta-atributos para classificação

- Para tarefas de classificação, há um grande número de meta-atributos, organizadas em diferentes grupos a depender do tipo:
 1. Simples, estatísticas, e de teoria da informação;
 2. Baseadas em modelo;
 3. Baseadas em performance;
 4. Baseadas em conceito e complexidade.

7

Meta-características usadas em tarefas de classificação



Simples, estatísticas, e de teoria da informação

- Várias características neste grupo derivam de variáveis dependentes e/ou independentes do dataset dado.
- **Meta-atributos simples:**
 - Número de exemplos (instâncias), n ;
 - Número de atributos (atributos), p ;
 - Número de classes, c ;
 - Proporção de atributos discretos;
 - Proporção de valores faltantes para o atributo x_i ;
 - Proporção de outliers para o atributo x_i .
- Alguns trabalhos usam variantes dessas meta-atributos. Ex.: ao invés de n , usam $\log(n)$, ou algumas razões dessas meta-atributos como n/c e n/p .

8

Meta-características usadas em tarefas de classificação

Simples, estatísticas, e de teoria da informação

- Um número de exemplos por classe (n/c) alto indica dados mais densos e portanto uma tendência a um problema mais fácil.
- Similarmente, o número de exemplos por dimensão (n/d) baixo pode indicar que podemos ter problemas com a "maldição da dimensionalidade".
- Algumas meta-atributos e referem a medidas que levam em conta um atributo em particular dos dados, ex.: Proporção de outliers para o atributo x_i .
- Operações de agregação das medidas dos vários atributos precisam ser realizadas para obter um valor geral para o dataset (média, mediana, máximo, mínimo, etc.).




Meta-características usadas em tarefas de classificação

Simples, estatísticas, e de teoria da informação

• Meta-atributos estatísticos:

- A abordagem mais comum para descrição de dados é utilizar estatística descritiva, tipicamente aplicável a atributos numéricos. Algumas dessas medidas focam em um atributo ou classe específica.
- Assimetria do atributo x_i ;
- Curtose atributo x_i .
- Probabilidade da classe y .



Meta-características usadas em tarefas de classificação

Simples, estatísticas, e de teoria da informação

• Meta-atributos estatísticas:

- Outras meta-atributos capturam o relacionamento entre duas ou mais atributos independentes. Ex.:
 - Correlação do atributo x_i com x_j , $\rho(x_i, x_j)$;
 - Covariância do atributo x_i com x_j .
- Estas medidas provêem uma estimativa da interdependência das variáveis.



Meta-características usadas em tarefas de classificação

Simples, estatísticas, e de teoria da informação

• Meta-atributos de teoria da informação


- Essas medidas são tipicamente associadas com atributos nominais.
 - Entropia do atributo x_i , $H(x_i)$;
 - Entropia da classe y , $H(y)$.
- Entropia da classe fornece uma estimativa da dificuldade da tarefa de classificação ou uma estimativa do desbalanceamento entre classes.
- Outras meta-atributos caracterizam o relacionamento entre dois ou mais atributos independentes:
 - Informação mútua entre x_i , y , $MI(x_i, y)$;
- Outras podem ser derivadas das medidas acima:
 - Dimensionalidade intrínseca da tarefa, $\frac{H(y)}{MI(x_i, y)}$;
 - Razão ruído-sinal, $\frac{H(y) - MI(x_i, y)}{MI(x_i, y)}$.



Meta-características usadas em tarefas de classificação

Baseadas em modelos

- Nesta abordagem, um modelo é induzido a partir do dataset e as meta-atributos são baseadas nas propriedades do modelo. Portanto, essas meta-atributos são obtidas de maneira indireta.
- O modelo a ser usado depende do tipo tarefa base de aprendizagem de máquina. Por exemplo, se a tarefa base é classificação, uma árvore de decisão pode ser utilizada.
- Propriedades de uma árvore de decisão que podem ser úteis como meta-atributos, capturando informações sobre a complexidade dos dados:
 - Número de nós;
 - Número de folhas;
 - Comprimento dos ramos;
 - Número de nós por atributo;
 - Número de folhas por classe;
 - Concordância entre as folhas.



13

Meta-características usadas em tarefas de classificação

Baseadas em performance

- **Landmarkers**
- Nesta abordagem, usa-se a estimativa rápida da performance de algoritmos utilizando algoritmos mais simples, ditos *landmarkers*, nos dados a caracterizar.
- Por exemplo, para estimar a performance de uma árvore de decisão, pode-se usar como *landmarker* uma árvore mais simples, como uma *decision stump* (árvore de decisão unitária).
- Além disso, landmarks também podem trazer características importantes sobre os dados.
- Estes são os *landmarkers* sugeridos por Pfahringer et al. (2000)
 - 1NN, caracteriza a esparsidade/dispersão dos dados, especialmente na fronteira de decisão;
 - Árvore de decisão (ou uma *decision stump*), caracteriza separabilidade dos dados;
 - Discriminante linear, caracteriza separabilidade dos dados;
 - Naive Bayes, caracteriza independência entre os atributos;

Pfahringer, B., Bensusan, H., and Giraud-Carrier, C. (2000). Meta-learning by landmarking various learning algorithms. In Langley, P., editor, Proceedings of the 17th International Conference on Machine Learning, ICML'00, pages 743–750.

14

Meta-características usadas em tarefas de classificação

Baseadas em performance

- **Landmarkers relativos**
 - São baseados na diferença (ou uma razão) de performance de dois algoritmos.
- **Landmarkers por subamostragem e curvas de aprendizado parcial**
 - Uma alternativa para obter estimativas rápidas da performance de um algoritmo em particular é rodar esse algoritmo num uma subamostra dos dados.
 - Uma característica mais informativa é obtida considerando uma sequência de landmarks por subamostragem para um único algoritmo. Representando uma curva de aprendizado parcial. Neste caso, a forma da curva pode trazer informações importantes.
- **Múltiplos landmarks**
 - É comum utilizar múltiplos landmarks como meta-atributos.

15

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- Este grupo de medidas busca caracterizar aspectos relacionados com a complexidade dos dados e podem ser úteis em tarefas de classificação. Consideramos os seguintes tipos de medidas:
 - Variação ou rugosidade de conceito no espaço de saída;
 - Sobreposição por atributos;
 - Separabilidade de classes.
- Mais detalhes a seguir.

16

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- **Variação ou rugosidade de conceito no espaço de saída**
- **Variação de conceito:**
 - Esta medida busca capturar a rugosidade do conceito alvo no espaço de instâncias.
 - Um espaço de saída rugoso significa que pequenas variações nos atributos altera o rótulo da instância.
 - Isto faz com instâncias vizinhas no espaço dos atributos tenham rótulos diferentes.
 - Calcula-se o $\delta(e_i, e_j)$. Para cada par de instâncias, ele é 0 se os rótulos forem iguais, e 1 se forem diferentes. Calcula-se a média sobre todos os possíveis pares.



17

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- **Variação ou rugosidade de conceito no espaço de saída**
- **Não-linearidade de um classificador linear (L_3):**
 - Esta medida é sensível à rugosidade da fronteira de decisão do classificador.
 - O objetivo é similar à medida anterior.
 - A ideia é fazer pequenas alterações nas instâncias e usá-las como teste, investigando os efeitos na taxa de erro do classificador linear.
 - As novas instâncias são geradas interpolando pares de instâncias originais de uma mesma classe. O classificador é treinado no conjunto original e testado nestas instâncias alteradas.
 - O erro de classificação representa a medida.



18

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- **Variação ou rugosidade de conceito no espaço de saída**
- **Não linearidade de um classificador 1NN:**
 - É obtida de maneira similar à anterior, porém um kNN com $k = 1$ é utilizado. O erro de classificação representa a medida.



19

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- **Sobreposição por atributos**
- **Razão de discriminante de Fisher (F1)**
$$F1_i = \frac{(\mu_{i1} - \mu_{i2})^2}{\sigma_{i1}^2 + \sigma_{i2}^2}$$
 - Onde μ_{i1} e σ_{i1} são a média e o desvio padrão do atributo i na classe 1. Similarmente μ_{i2} e σ_{i2} referem-se à classe 2.
 - Para obter o valor final de F1, costuma-se usar o valor máximo ao longo de todos os atributos. $F1 = \max_i F1_i$
 - Usa-se o valor máximo pois se um atributo tiver o F1 alto, sabe-se que as classes estão bem separadas em pelo menos uma dimensão.
 - A ideia é que se as médias forem distantes e os desvios padrão pequenos e parecidos existe uma boa separação entre as classes, indicando um problema de classificação mais fácil.



20

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- Sobreposição por atributos

- Volume da região de sobreposição (F2)

$$F2 = \prod_{i=1}^d \frac{\max(0, \min(\max(x_i^{C_1}), \max(x_i^{C_2})) - \max(\min(x_i^{C_1}), \min(x_i^{C_2})))}{\max(\max(x_i^{C_1}), \max(x_i^{C_2})) - \min(\min(x_i^{C_1}), \min(x_i^{C_2}))}$$

- Ideia do cálculo:

1. **Identificação do Intervalo de Sobreposição:** Para um atributo específico, encontra-se o valor máximo da classe que possui os menores valores e o valor mínimo da classe que possui os maiores valores.
 2. **Cálculo do "Volume" Individual:** Mede-se o comprimento desse intervalo de sobreposição e divide-se pela amplitude total (o range) combinada das duas classes para normalizar o valor.
- F2 = 0: Indica que existe pelo menos um atributo onde as classes não se sobrepõem de forma alguma (são perfeitamente separáveis por um hiperplano ortogonal ao eixo). Isso sinaliza um problema de classificação muito simples.
 - F2 > 0: Indica que há sobreposição em todas as dimensões. Quanto maior o valor, maior é o "volume" do espaço de busca onde as classes estão misturadas, o que aumenta a ambiguidade para o classificador.

21

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- Sobreposição por atributos

- Eficiência do atributo (F3 e F4)

- O objetivo é caracterizar o quanto cada atributo contribui para a separação das classes.
- Se alguns valores de atributo ocorre tanto em uma classe quanto em outra, as classes são ambíguas naquela região de valores.

- F3 - Eficiência máxima individual

1. Para cada atributo, identifica-se a região de sobreposição (como vimos no F2).
2. Conta-se quantos exemplos estão fora dessa região de sobreposição.
3. A eficiência de um atributo é a razão entre o número de exemplos fora da sobreposição e o total de exemplos.
4. O F3 é o valor máximo entre todos os atributos.

- O que indica?

- F3 alto: Existe pelo menos um atributo que consegue classificar uma grande parte dos dados de forma limpa e inequívoca.
- F3 baixo: Mesmo o melhor atributo tem quase todos os seus exemplos misturados na zona de sobreposição.

22

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- Sobreposição por atributos

- Eficiência do atributo (F3 e F4)

- F4 - Eficiência coletiva dos atributos

1. Começa-se com o atributo mais eficiente (em termos de F3) e removem-se os exemplos que ele já separou corretamente.
2. Com os exemplos restantes (aqueles que estavam na zona de sobreposição), seleciona-se o próximo atributo que melhor separa esse "resíduo".
3. O processo se repete até que não restem mais atributos (ou exemplos).
4. O F4 é a proporção total de exemplos que foram "limpos" por esse processo coletivo.

- O que indica?

- F4 alto: Indica que, embora os atributos individualmente possam não ser perfeitos, a combinação delas (uma corrigindo a ambiguidade da outra) consegue descrever bem o problema.
- F4 baixo: Sugere um dataset altamente complexo onde, mesmo unindo forças, os atributos não conseguem criar zonas claras de separação para a maioria dos pontos.

23

Meta-características usadas em tarefas de classificação

Baseadas em conceito e complexidade.

- Separabilidade de classes

- Ho e Basu (2002) propuseram dois grupos de medidas. Um caracteriza a separabilidade linear e o outro se dois conjuntos de exemplos vêm de distribuições diferentes. Exemplos:

- **Separabilidade Linear:** Utiliza-se a taxa de erro de um classificador linear.

- **Fração de pontos na fronteira das classes (N1):**

- Verifica se duas amostras (da classe 1 e 2) vêm da mesma distribuição.
- Usa para isso o conceito de *minimum spanning tree (MST)*, ou "árvore geradora mínima".
- Para construir a MST, conecta-se todos os pontos do dataset em uma rede (grafo), de modo que a soma das distâncias entre os pontos conectados seja a menor possível e não existam ciclos.
- O MST conecta pontos (instâncias) independentemente de suas classes.
- O número de pontos conectados à classe oposta representa os pontos na fronteira das classes. O N1 é a fração desses pontos com relação ao todo.
- **O que o valor de N1 nos diz?**
 - N1 próximo de 0: As classes estão em "ilhas" bem separadas. Problemas assim são fáceis de resolver e a redução de dimensionalidade linear costuma ser suficiente.
 - N1 próximo de 1: Existe um alto grau de entrelaçamento. Isso indica que a fronteira de decisão é altamente não linear ou que há muito ruído nos dados.



Ho, T. and Basu, M. (2002). Complexity measures of supervised classification problems. IEEE Transactions on Pattern Analysis and Machine Intelligence, 24(3):289–300.

24

Meta-características usadas em tarefas de regressão



Tipos de meta-atributos para regressão

- Para tarefas de regressão, muitos pesquisadores propuseram abordagens de meta-aprendizagem e consequentemente discutiram meta-features (Lorena et al. 2018):
 1. Simples e estatísticas;
 2. Baseadas em complexidade;
 3. Baseadas em suavidade (smoothness);

Lorena, A., Maciel, A., de Miranda, P., Costa, I., and Prudêncio, R. (2018). Data complexity meta-features for regression tasks. Machine Learning, 107(1):209–246.

25

Meta-características usadas em tarefas de regressão Simples e estatísticas



- São similares às meta-features do mesmo grupo para classificação.
- Muitas podem ser reusadas e não as revisitaremos.
- Porém, como agora o alvo é numérico (regressão) todas os atributos que envolvem a variável alvo precisam ser adaptados.
- Algumas meta-features que envolvem apenas uma variável são:
 - Coeficiente de variação a variável alvo: $\sigma(y)/\mu(y)$
 - Número de outliers da variável alvo y .
- Outras capturam o relacionamento entre duas variáveis como as baseadas em correlações.
 - Correlação entre o atributo x_i e variável y , $\rho(x_i, y)$
 - Correlação entre o atributo x_i e o atributo x_j , $\rho(x_i, x_j)$

26

Meta-características usadas em tarefas de regressão Simples e estatísticas



- Outras meta-features podem ser também derivadas do conjunto básico por meio de várias operações, incluindo agregação (média, mediana, etc.)
- Duas meta-features derivadas são de particular importância:
 - Máxima correlação entre atributos e o alvo, ρ_{max} ;
 - Correlação média entre atributos e a variável alvo, $\bar{\rho}$.
- Um valor alto para ρ_{max} indica que pode ser possível obter boas predições utilizando apenas o atributo correspondente.

27

Meta-características usadas em tarefas de regressão Baseadas em complexidade



- Neste grupo destacam-se duas meta-features comuns às meta-features para tarefas de regressão:
 - **Eficiência máxima individual do atributo:**
 - Adaptação: ao invés de medir o efeito do atributo em separabilidade de classes, mede-se o efeito do atributo em correlação com o alvo.
 - Para cada atributo, o método identifica o menor número de instâncias que precisam ser removidas até que uma alta correlação (de acordo com algum limiar) entre o atributo e o alvo seja obtido.
 - Os números de exemplos removidos são convertidos em proporções.
 - A medida é dada pela mínima proporção identificada entre os vários atributos.
 - **Eficiência coletiva dos atributos**
 - Aqui faz-se um processo iterativo de identificar o atributo com a mais alta correlação, fazer um fit linear, e eliminar exemplos com pequeno valor residual.
 - A medida corresponde à proporção de exemplos que permanecem após todas os atributos terem sido examinados.
- Em ambas as medidas valores baixo indicam problemas relativamente mais fáceis.

28

Meta-características usadas em tarefas de regressão

Baseadas em complexidade

- Lorena et al. (2018) inclui essas duas medidas entre as baseadas em complexidade, no entanto, como são derivadas de um modelo em particular (regressor linear), poderíamos chamá-las também de **baseadas em modelos**:
 - **Valor médio absoluto de um regressor linear:** Esta medida realiza a média dos resíduos de uma regressão linear múltipla.
 - **Variância dos resíduos de um regressor linear:** Esta realiza a média dos quadrados dos resíduos de uma regressão linear múltipla.
- Em ambas as medidas, valores pequenos indicam problemas mais simples.



29

Meta-características usadas em tarefas de regressão

Baseadas em suavidade

- **Similaridade de valores do alvo para exemplo similares:**
 - Esta medida tem um objetivo similar a *variação de conceito* das MFs sobre classificação.
 - Ela tenta estimar a suavidade ou a rugosidade de exemplos similares no espaço de saída.
 - Usa uma MST para unir os exemplos mais simples no espaço de entrada (atributos), pesando as arestas de acordo com a distância Euclidiana.
 - A medida então captura a distância média entre valores de alvo.
- **Similaridade dos atributos para exemplos com alvos similares:** Complementa a medida anterior. Mede o quão similares são os atributos de exemplos com valores de alvo similares.
- **Erros de um regressor 1NN:** É uma adaptação da meta-feature similar para classificação (1NN landmarker). Uma medida de erro adequada para regressão (como MSE) é utilizada aqui.



30

Meta-características usadas em tarefas de regressão

Medidas de não linearidade

- Outras medidas, adaptadas das medidas de classificação são bastante úteis, a saber:
 - Não linearidade de um regressor linear;
 - Não linearidade de um regressor 1NN.



31

Meta-características usadas em tarefas de séries temporais

- O problema sobre como aplicar meta-aprendizagem a tarefas de predição de séries temporais foi investigado por vários autores. Ex.: Adya et al. (2001); Prudêncio e Ludermir (2004); dos Santos et al. (2004); Lemke e Gabrys (2010), etc.
- A caracterização dos dados desse tipo de problema precisa levar em conta que trata-se de uma sequência de valores. Ou seja, há uma ordem relevante entre as instâncias.
- Lemke e Gabrys (2010) dividiram as medidas em quatro grupos:
 - Estatísticas gerais;
 - Características no domínio da frequência;
 - Características de autocorrelação;
 - Medidas de diversidade (úteis para ensembles).



Lemke, C. and Gabrys, B. (2010). Meta-learning for time series forecasting and forecast combination. Neurocomputing, 74:2006-2016

32

Meta-características usadas em tarefas de séries temporais

Estatísticas gerais

- Para calcular algumas das medidas de estatística descritiva de uma série temporal, Lemke e Gabrys (2010) primeiro *destendencionam* usando uma regressão polinomial. Algumas medidas usadas são:
 - Comprimento da série temporal;
 - Desvio padrão da série *destendencionada*;
 - Assimetria e curtose;
 - Tendência, calculada como $\text{std}(\text{serie})/\text{std}(\text{serie destendencionada})$.
 - Número de pontos de virada (turning points)
 - Número de mudanças de passo;
 - Estimativa de não linearidade.

Lemke, C. and Gabrys, B. (2010). Meta-learning for time series forecasting and forecast combination. *Neurocomputing*, 74:2006–2016



33

Meta-características usadas em tarefas de séries temporais

Características no domínio da frequência

- Medidas baseadas em frequência podem ser derivadas de uma Transformada de Fourier Rápida (FFT) aplicada aos dados da série temporal. Lemke e Gabrys (2010) propuseram essas meta-características:
 - Frequências dos três maiores valores;
 - Valor máximo indicando o componente cíclico sazonal mais forte;
 - Número de picos com pelo menos 60% do componente máximo.



34

Meta-características usadas em tarefas de séries temporais

Características de autocorrelação

- Essas medidas fornecem informações sobre a estacionaridade e sazonalidade da série temporal.
- Autocorrelação e autocorrelação parcial fornecem informações importantes sobre a série. São calculados com relação a pontos de dados que incluem um *lag* de d posições. Lemke e Gabrys (2010) propuseram:
 - Autocorrelação nos lags 1 e 2;
 - Autocorrelação parcial nos lags 1 e 2;
 - Autocorrelação parcial nos lags 7 ou 30 (dias), capturando sazonalidade semanal ou mensal.



35

Meta-características usadas em tarefas de agrupamento

- Várias meta-features podem ser empregadas quando a tarefa de nível base é agrupamento.
- Algumas meta-features utilizadas em classificação também podem ser empregadas para tarefas de agrupamento, desde que sejam não supervisionadas (não usam o valor de y).
- No entanto, meta-features específicas para agrupamento são de especial interesse e vêm sido estudadas recentemente (de Souto et al., 2008; Soares et al., 2009; Ferrari and de Castro, 2015; **Pimentel** and de Carvalho, 2019).
- Basicamente, as meta-features usadas em agrupamento podem ser divididas nesses grupos:
 - Simples, estatísticas e de teoria da informação;
 - Baseadas em modelos;
 - Baseadas em performance.



Pimentel, B. A. and de Carvalho, A. C. (2019). A new data characterization for selecting clustering algorithms using meta-learning. *Information Sciences*, 477:203 – 219

36

Meta-características usadas em tarefas de agrupamento

Simples, estatísticas, e de teoria da informação

- Como os dados de agrupamento não incluem uma variável alvo, é possível usar apenas meta-features que envolvam as variáveis independentes (atributos).
- Ferrari e de Castro (2015), por exemplo, usaram um subconjunto apropriado das MFs para classificação.
- Pimentel e de Carvalho (2019) propuseram meta-features descrevendo a distribuição de correlações de rankings entre instâncias.

Ferrari, D. and de Castro, L. (2015). Clustering algorithm selection by meta-learning systems: A new distance-based problem characterization and ranking combination methods. *Information Sciences*, 301:181-194.

37

Meta-características usadas em tarefas de agrupamento

Baseadas em modelo

- Ferrari e de Castro (2015) adaptaram a ideia de MFs baseadas em modelo para as tarefas de agrupamento.
- Eles definiram um vetor $\mathbf{d}$ contendo as distâncias Euclidianas para a par $d_{i,j}$ entre todos os pares de instâncias i e j para um dado dataset.
- O vetor é então normalizado em um intervalo $[0,1]$ e caracterizado usando medidas estatísticas. Divididas em três grupos:
 - Medidas simples: Média, variâncias, desvio padrão, assimetria e curtose.
 - Medidas de histograma: um histograma é construído de acordo com a distribuição dos valores em $\mathbf{d}$. Usa-se 10 intervalos (*bins*) e para cada um deles gera-se uma meta-feature que captura a porcentagem de valores nesse intervalo.
 - Medidas alternativas da distribuição: Primeiro gera-se z-scores (normaliza-se) e depois segue-se o processo do grupo anterior.

Ferrari, D. and de Castro, L. (2015). Clustering algorithm selection by meta-learning systems: A new distance-based problem characterization and ranking combination methods. *Information Sciences*, 301:181-194.

38

Meta-características usadas em tarefas de agrupamento

Baseadas em performance

- Alguns autores usaram *medidas de validação interna* no framework de meta-aprendizagem para agrupamento (Vukicevic et al., 2016; Tomp et al., 2019).
- Essas medidas de validação interna podem ser obtidas após a aplicação de K-means com uma configuração fixa e incluem o Coeficiente de Silhueta ou o Índice de Davies-Bouldin.
- Com isso, várias das medidas que foram usadas para classificação, como os *landmarkers* e os *landmarkers* com subamostragem, puderam ser adaptados ao domínio do agrupamento.

Vukicevic, M., Radovanovic, S., Delibasic, B., and Suknovic, M. (2016). Extending metalearning framework for clustering gene expression data with component-based algorithm design and internal evaluation measures. *International Journal of Data Mining and Bioinformatics (IJDMB)*, 14(2).

Tomp, D., Muravyov, S., Filchenkov, A., and Parfenov, V. (2019). Meta-learning based evolutionary clustering algorithm. In *Lecture Notes in Computer Science*, Vol. 11871, pages 502-513.

39

Derivando novas meta-características a partir do conjunto básico

Gerando novas medidas por agregação

- Como vimos, muitas características, como a assimetria, são calculadas para cada atributo numérico.
- Dado que o número de atributos em cada dataset varia, isto significaria que o número de medidas de assimetria para cada dataset também varia.
- No entanto, o vetor de meta-features deve ter o mesmo número de elementos para cada dataset.
- A abordagem mais comum para resolver este problema é a agregação por alguma medida de sumário, como a média.
- O problema é que informação é perdida no processo.
- Kalousis e Theoharis (1999) propuseram uma outra forma de agregação mais fina. Usando histogramas. Por exemplo: Ao invés da média da assimetria, número de atributos com assimetria menor que 0.2, entre 0.2 e 0.4, e maior que 0.4.

Kalousis, A. and Theoharis, T. (1999). NOEMON: Design, implementation and performance results of an intelligent assistant for classifier selection. *Intelligent Data Analysis*, 3(5):319-337.

40

Derivando novas meta-características a partir do conjunto básico

Gerando um conjunto completo de meta-features

- Muitos trabalhos de meta-aprendizagem partem de um conjunto de meta-features que pode ser considerado incompleto, por exemplo.
- Não incluem todos os grupos de meta-features;
- Não usam mais de uma medida de agregação.
- Entre as medidas de agregação possíveis, temos: Média, desvio padrão, mínimo, máximo, primeiro quartil (Q1), Q2, Q3, e as medidas de histograma.
- Pinto (2018) mostrou que um sistema que usa um conjunto mais completo atingiu maior performance do que com um conjunto inicial menor.

Pinto, F. (2018). Leveraging Metalearning for Bagging Classifiers. PhD thesis, University of Porto, FEUP.



41

Derivando novas meta-características a partir do conjunto básico

Transformação de features por seleção e projeção

- Principal Component Analysis (PCA): Pode ser usada para projetar meta-features e um espaço de baixa dimensão que inclui os componentes principais. Smith-Miles et al. (2014).
- Outras técnicas de redução de dimensionalidade / projeção também podem ser aplicadas.

Smith-Miles, K., Baatar, D., Wreford, B., and Lewis, R. (2014). Towards objective measures of algorithm performance across instance space. Computers & Operations Research, 45:12–24.



42

Derivando novas meta-características a partir do conjunto básico

Construção de novas features latentes por fatoração de matriz

- Fusi et al. (2018) propuseram aplicar fatoração matricial probabilísticas para decompor a matriz de performances $Y \in \mathbb{R}^{N \times D}$, onde N é o número de algoritmos e D é o número de datasets.
- Cada célula de Y é a performance de um algoritmo em um dataset em particular.
- Assim, a PMF é aplicada para decompor $Y \approx XW$ obtendo as matrizes $X \in \mathbb{R}^{N \times Q}$ e $W \in \mathbb{R}^{Q \times D}$.
- Matriz $W \in \mathbb{R}^{Q \times D}$: Mapeia cada dataset para um espaço latente de tamanho Q . Cada coluna de W é um vetor de números que descreve as "propriedades intrínsecas" daquele dataset que fazem os algoritmos performarem de certa forma.
- Matriz $X \in \mathbb{R}^{N \times Q}$: Mapeia cada algoritmo para o mesmo espaço latente, descrevendo quais tipos de características de dados aquele algoritmo "gosta" ou "domina".

Fusi, N., Sheth, R., and Elilbol, M. (2018). Probabilistic matrix factorization for automated machine learning. In Advances in Neural Information Processing Systems 32, NIPS'18, pages 3348–3357.



43

Seleção de Meta-features

- Todo esforço de definição de novas meta-features deve ser balanceado com uma etapa a posteriori de seleção das meta-features.
- É importante selecionar um conjunto adequado de medidas.
- Como em meta-aprendizagem o número de exemplos (datasets) costuma ser pequeno. Um número muito grande de meta-features pode ocasionar *overfitting* e portanto previsões ruins em datasets não vistos.
- A seleção pode ser feita durante o desenvolvimento do sistema de MTL, incluindo somente medidas que se espera relevantes de acordo com características do problema e conhecimento de especialistas.
- Alternativamente, pode-se incluir o maior número possível de meta-features e em seguida aplicar um método de seleção de features para obter um subconjunto.
- Todorovski et al. (2000) mostrou que um método baseado em "eliminação reversa", que remove um atributo por vez e avalia o impacto da remoção de cada atributo, pode melhorar a performance.


Todorovski, L., Brazdil, P., and Soares, C. (2000). Report on the experiments with feature selection in meta-level learning. In Brazdil, P. and Jorge, A., editors, Proceedings of the Data Mining, Decision Support, Meta-Learning and ILP Workshop at PKDD 2000, pages 27–39.



44


Estudo da importância das meta-features no domínio de classificação

- Ao utilizar treinar algoritmos baseados em árvore a nível meta, um subproduto importante é o vetor de importâncias das meta-features para o modelo resultante.
- Amorim et al. (2024) propôs um método para recomendação de técnicas de normalização em problemas de classificação usando meta-aprendizagem.



De Amorim, L. B. V., Cavalcanti, G. D. C., Cruz, R. M. O. (2024). Meta-scaler: a meta-learning framework for the selection of scaling techniques. IEEE Transactions on Neural Networks and Learning Systems, Vol 36, Issue 3, March 2025. Pages 4805 - 4819.

45



46

Questões de representação específicas a algoritmos

- Medidas úteis para decidir entre dois algoritmos:
 - O conjunto de algoritmos base também precisa ser levado em conta no desenvolvimento de meta-features. Ex.:
 - A **proporção de atributos contínuos** pode ser útil para discriminar entre Naive Bayes e kNN, mas não entre Naive Bayes e um algoritmo baseado em regras (ex.: DT)
 - Isso porque sabe-se que kNN funciona melhor para atributos contínuos do que Naive Bayes, porém não é fácil saber se funcionará melhor que uma DT.
 - Uma abordagem interessante é transformar o problema de AS em vários problemas binários (predizer entre algoritmo A ou B).
 - Neste caso, para cada par, pode-se usar um conjunto de meta-features diferentes.
 - Quando os algoritmos base são similares necessitam do desenvolvimento de novas meta-features capazes de discriminar entre as nuances de cada um.
 - Um caso em particular é quando os dois algoritmos base são do mesmo tipo, ex.: SVM com diferentes kernel.

47

Similaridade entre datasets

Similaridade baseada em meta-features:

- Uma forma de medir o quão similares dois datasets são, é por meio do cálculo de distâncias entre os mesmos no espaço das meta-features.
- Ou seja, consideramos cada dataset como um vetor de meta-features e calculamos alguma medida de distância. Ex.: Euclidiana ou Manhattan.
- De fato, o algoritmo kNN realiza justamente este cálculo ao identificar os k vizinhos mais próximos para decidir a classe da instância de teste.

$$Dist_{mf}(d_{new}, d_i) = \sum_{p=1}^m \frac{|f_{d_{new},p} - f_{d_i,p}|}{\max(f_{*,p}) - \min(f_{*,p})}$$

Similaridade baseada nas performances:

- Uma outra maneira de medir a similaridade é com base nas performances resultantes da aplicação de diferentes algoritmos. Semelhante ao uso de landmarks.

48