



Meta-aprendizagem

Abordagens de meta-aprendizagem para seleção de algoritmos - outras técnicas

Prof. Lucas Amorim - lucas@ic.ufal.br

1

Introdução



- Nas aulas anteriores exploramos diferentes maneiras de construir um sistema de meta-aprendizagem para recomendar algoritmos;
- Vimos a abordagem que usa como meta-modelo um classificador e recomenda o melhor algoritmo;
- Vimos duas abordagens baseadas em regressão e rankings;
- Revisaremos brevemente abordagens já vistas, sob a ótica de EPMs e introduziremos as abordagens que realizam comparações aos pares.

2

Sumário



- Introdução;
- Utilizando modelos de regressão em sistemas de meta-aprendizagem;
- Utilizando classificação em nível meta para a predição de aplicabilidade;
- Métodos baseados em comparação aos pares;
- Abordagem aos pares para um conjunto de algoritmos;
- Abordagem iterativa para condução de testes aos pares;
- Uso de florestas ART;

3

Utilizando modelos de regressão em sistemas de meta-aprendizagem



- Entre as abordagens de regressão (como meta-modelo) temos a que converte performances de nível base em posições relativas (rank), e prediz um ranking de algoritmos em nível base, junto com suas configurações.
- Para simplificar, representaremos cada combinação de algoritmo e parâmetros a_θ como $\theta \in \Theta$. Onde o conjunto Θ representa todas as possíveis configurações.
- A ideia básica é estimar a performance de cada configuração em nível base e selecionar aquela que alcança os melhores resultados.
- Esses modelos são comumente chamados de EPMs - Empirical Performance Models, ou seja, Modelos de Performances Empíricas. Leyton-Brown et al., 2009; Hutter et al., 2014; Eggenberger et al., 2018.
- As abordagens existentes de EPMs podem ser divididas em dois grupos:
 - As que utilizam meta-dados obtidos apenas do dataset corrente.
 - As que utilizam meta-dados obtidos de outros datasets também.

Eggenberger, K., Lindauer, M., Hoos, H., Hutter, F., and Leyton-Brown, K. (2018). Efficient benchmarking of algorithm configuration procedures via model-based surrogates. Special Issue on Metalearning and Algorithm Selection, Machine Learning, 107(1).

4

Utilizando modelos de regressão em sistemas de meta-aprendizagem

Modelos de Performances Empíricas (EPMs)



• Abordagens que usam meta-dados apenas do dataset corrente:

- Esta abordagem é a base do sistema Auto-WEKA (Thornton et al., 2013);
- Quando meta-dados de outros datasets não estão disponíveis, a única fonte de meta-dados pode ser de execuções prévias das configurações no próprio dataset.
- Primeiramente várias configurações prévias são testadas e os resultados constituem os meta-dados.
- As configurações prévias podem ser selecionadas aleatoriamente ou por alguma outra forma baseada portfólio.
- Os meta-dados consistem de n casos (meta-exemplos) da forma:

$$MetaD \equiv (\theta_i, P_i)^n$$

- Onde $i = \{1, 2, \dots, n\}$, θ_i representam a i -ésima configuração de algoritmo, e P_i é a performance desta configuração.
- Um meta-regressor é então treinado com esses meta-dados. ($MetaM \leftarrow Train(MetaD)$).
- Como em qualquer tarefa de aprendizado, a performance depende, dentre outras coisas, do número de instâncias.
- O EPM $MetaM$ pode ser usado para estimar a performance de uma nova configuração θ_k que não existe em $MetaD$:

$$\hat{P}_k \leftarrow Predict(MetaM, \theta_k)$$

Thornton, C., Hutter, F., Hoos, H. H., and Leyton-Brown, K. (2013). Auto-WEKA: Combined selection and hyperparameter optimization of classification algorithms. In Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pages 847–855. ACM.

5

Utilizando modelos de regressão em sistemas de meta-aprendizagem

Modelos de Performances Empíricas (EPMs)



• Abordagens que usam meta-dados de outros datasets:

- Estas são as abordagens atualmente mais comuns. Em que os meta-dados são constituídos a partir da configuração θ_i , do dataset d_j , e das performances:

$$MetaD \equiv (\theta_i, d_j, P_{i,j})_{i=1, j=1}^{n, m}$$

- Neste caso, cada dataset d_j é representado pelas meta-features $mf(d_j)$.
- Como anteriormente, um meta-regressor é então treinado com esses meta-dados. ($MetaM \leftarrow Train(MetaD)$).
- As predições são feitas invocando:

$$\hat{P}_k \leftarrow Predict(MetaM, \theta_k, d_i)$$

6

Utilizando modelos de regressão em sistemas de meta-aprendizagem

Modelos de Performances Empíricas (EPMs)



• Transformando predições de performance em rankings

- Como vimos anteriormente, um conjunto de estimativas de performances de diferentes algoritmos de nível base, pode ser transformado em rankings através da ordenação dos valores.
- Este ranking pode ser utilizado para priorizar testes dos algoritmos no conjunto de dados em questão.
- No entanto, em muitos casos, o usuário simplesmente requer uma predição do melhor algoritmo e não as performances de todos.

7

Utilizando modelos de regressão em sistemas de meta-aprendizagem

Modelos de Performances Empíricas (EPMs)



• Vantagens e desvantagens de predição de performances

• Vantagens:

- ✓ Ao fornecer estimativas de performance para cada algoritmo, ao invés de postos em um ranking, mais informação é fornecida.
- ✓ Estimativas de performance podem ser convertidas em rankings.
- ✓ O problema pode ser quebrado em múltiplas regressões, o que o torna modular, facilitando a inclusão ou remoção de algoritmos base no portfólio.

• Desvantagens:

- ✗ Gerar uma regressão para cada algoritmo base não é trivial.
- ✗ Pode ser mais difícil interpretar os modelos para entender quando escolher algoritmo A ou B.
- ✗ Espera-se que aprender a prever performances individuais seja muito mais difícil do que discriminar entre um número finito de classes ou prever um ranking.
- ✗ Tratando como problemas independentes de regressão não se leva em consideração as performances relativas (que é o que deve interessar mais) e sim cada performance individualmente.

Tabela: Quatro exemplos de regras para prever o erro de dois algoritmos. (Gama e Brazdil, 1995)

Algorithm	Error	Estimated	
		Conditions	
C4.5	22.5	$\leftarrow fract1 > 0.2 \wedge cost > 0$	
c4.5	58.2	$\leftarrow fract1 < 0.2$	
CN2	8.5	$\leftarrow Ha \leq 5.6$	
CN2	60.4	$\leftarrow Ha > 5.6 \wedge cost > 0$	

Gama, J. and Brazdil, P. (1995). Characterization of classification algorithms. In Pinto-Ferreira, C. and Mamede, N. J., editors, Progress in Artificial Intelligence, Proceedings of the Seventh Portuguese Conference on Artificial Intelligence, pages 189–200. Springer-Verlag.

8

Utilizando classificação em nível meta



- Ao invés de construir EPMs (e utilizar regressão em nível meta), muitos trabalhos têm explorado a simplificação do problema em nível meta transformando-o num problema de classificação.
- Uma das abordagens é o método simples já visto do “melhor algoritmo”, que substitui a matriz de performances por uma coluna com o rótulo do melhor classificador.
- Outras abordagens são possíveis como:
 - Predição de aplicabilidade de classificadores
 - Métodos baseados em comparações aos pares:
 - One vs. One
 - One vs. All (rest)

9

Utilizando classificação em nível meta



Qual algoritmo de classificação utilizar?

- Muitos algoritmos de classificação já foram empregados em meta-aprendizagem para construção do meta-modelo.
- Vários trabalhos, no entanto, têm demonstrado o bom desempenho de meta-classificadores baseados em árvores de decisão.
- Um ponto a favor de métodos baseados em árvores de decisão é sua interpretabilidade, contribuindo para insights interessantes na área de domínio a que se propõe o sistema de meta-aprendizagem.

10

Utilizando classificação em nível meta



Utilizando classificação em nível meta para a predição de aplicabilidade

- Em um trabalho de Brazdil et al. (1994), utilizou-se classificação no nível meta para prever se um determinado algoritmo de classificação é aplicável (com erro relativo baixo) ou não aplicável a um dataset alvo.
- Seguindo a notação vista: $MetaD \equiv (\theta_i, d_j, P_{i,j})_{i=1, j=1}^{n, m}$
- Neste trabalho, as performances $P_{i,j}$ foram discretizadas em dois possíveis valores “aplicável” ou “não aplicável”.
- Ex.: limiar de aplicabilidade em 0.8:

SVM_1	SVM_2	DT	RF	KNN
0.8	0.9	0.75	0.82	0.7
0.7	0.6	0.8	0.83	0.75
0.55	0.66	0.65	0.68	0.61
0.9	0.91	0.92	0.9	0.95
0.88	0.87	0.80	0.85	0.82



SVM_1	SVM_2	DT	RF	KNN
A	A	NA	A	NA
NA	NA	A	A	NA
NA	NA	NA	NA	NA
A	A	A	A	A
A	A	A	A	A

Brazdil, P., Gama, J., and Henery, B. (1994). Characterizing the applicability of classification algorithms using meta-level learning. In Bergadano, F. and De Raedt, L., editors, Proceedings of the European Conference on Machine Learning (ECML94), pages 83–102. Springer-Verlag.

11

Utilizando classificação em nível meta



Métodos baseados em comparação aos pares

- Vários autores investigaram a possibilidade de usar modelos que realizam comparação aos pares para a tarefa de prever o melhor algoritmo em potencial, ou, alternativamente, um ranking de algoritmos.
- Os primeiros trabalhos focaram no problema de prever qual de dois algoritmos tem maior chance de ser o melhor em um novo dataset (Pfahring et al., 2000; Fürnkranz and Petrak, 2001; Soares et al., 2001; Leite and Brazdil, 2004, 2005).
- Depois, investigou-se como o método de comparação aos pares pode ser utilizado para fornecer um ranking de todos os algoritmos, ou identificar o melhor e todos os outros com performance similar.
- Alguns métodos geram vários modelos aos pares, que em seguida são usados para obter o ranking (Leite and Brazdil, 2010; Sun and Pfahring, 2012, 2013).
- Outros usam um método iterativo que detalharemos mais à frente (Leite and Brazdil, 2007; van Rijn et al., 2015).

ref

12

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares



Testes aos pares explorando landmarks

- Pfahringer et al. (2000) propôs o uso de versões simplificadas e mais rápidas de algoritmos, os landmarks, em comparações aos pares.
- Os autores mostraram que os landmarks podem ser usados para o problema de prever qual de dois algoritmos tem maior probabilidade de ser o melhor em um novo dataset. (outras propostas aplicaram landmarks com subamostragem)
- Os resultados iniciais não mostraram uma vantagem clara da abordagem.
- No entanto, mostrou-se mais tarde que o método que usa a performance em uma única subamostra dos dados é competitivo. (van Rijn et al., 2015; van Rijn, 2016) Este método é conhecido como *best-on-sample* (melhor na amostra).
- Um resultado surpreendente é que aumentando o número de amostras não levou a melhoria de performance. Isto motivou a abordagem descrita a seguir.

Pfahringer, B., Bensusan, H., and Giraud-Carrier, C. (2000). Meta-learning by landmarking various learning algorithms. In Langley, P., editor, Proceedings of the 17th International Conference on Machine Learning, ICML'00, pages 743-750.

van Rijn, J. N. (2016). Massively collaborative machine learning. PhD thesis, Leiden University.

van Rijn, J. N., Abdulrahman, S., Brazdil, P., and Vanschoren, J. (2015). Fast algorithm selection using learning curves. In International Symposium on Intelligent Data Analysis XIV, pages 298-309.

13

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares



Método aos pares orientado a curvas de aprendizado parcial

- Leite e Brazdil (2004, 2005) propuseram uma variação do método anterior, usando a performance em uma série de amostras com tamanhos crescentes, como características dos dados. Esta série de performances representa uma **curva de aprendizado parcial**.
- O método usa um meta-dataset que inclui curvas de aprendizado completas de todos os algoritmos e outros datasets.
- Para o dataset alvo, apenas curvas de aprendizado parcial são necessárias. De maneira que processo leva menos tempo do que obter a performance no dataset completo.
- Com base na curva parcial para o dataset alvo, e curvas completas nos datasets de treino, o meta-algoritmo pode determinar a sua recomendação.




Fig.: Exemplo de curva de aprendizagem para o dataset "letter".
Fonte: van Rijn (2016)

Leite, R. and Brazdil, P. (2004). Improving progressive sampling via meta-learning on learning curves. In Boulicaut, J.-F., Esposito, F., Giannotti, F., and Pedreschi, D., editors, Proc. of the 15th European Conf. on Machine Learning (ECML2004), LNAI 3201, pages 250-261. Springer-Verlag.

Leite, R. and Brazdil, P. (2005). Predicting relative performance of classifiers from samples. In Proceedings of the 22nd International Conference on Machine Learning, ICML'05, pages 497-503, NY, USA. ACM Press.

14

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares



Método aos pares orientado a curvas de aprendizado parcial

- Dado um novo dataset d_i e dois algoritmos a_p e a_q , qual dos dois será melhor?
- O método segue estes passos:
 1. Representa as curvas de aprendizagem;
 2. Obtém as curvas parciais de a_p e a_q em d_i ;
 3. Identifica, no meta-dataset, os datasets com curvas de a_p e a_q mais similares às curvas em d_i ;
 4. Usa as curvas desses datasets para prever a performance de a_p e a_q em d_i ;
 5. Prediz qual dos dois algoritmos obterá maior performance.
- A ideia principal é economizar tempo.
- Veremos os detalhes dessas etapas a seguir.




Fig.: Exemplo de curva de aprendizagem para o dataset "letter".
Fonte: van Rijn (2016)

Leite, R. and Brazdil, P. (2005). Predicting relative performance of classifiers from samples. In Proceedings of the 22nd International Conference on Machine Learning, ICML'05, pages 497-503, NY, USA. ACM Press.

15

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares



Método aos pares orientado a curvas de aprendizado parcial

Representação de curvas de aprendizado parcial:

- Cada curva de aprendizado parcial é representada por uma sequência de valores de performance de um dado algoritmo em amostras de tamanhos crescentes de um dataset.
- Formalmente, uma curva de aprendizado parcial P_{a_p, d_i} é representada por uma sequência de elementos da forma $p_{a_p, d_i, k}$, onde a_p representa um algoritmo, d_i um dataset, e k um índice de uma amostra que varia de 1 a k_{max} .
- Conforme trabalho anterior de Provost et al. (1999), os tamanhos das amostras seguem uma progressão geométrica. Leite e Brazdil (2005) determinaram o valor da k -ésima amostra como o inteiro mais próximo a $2^{6+0.5k}$.

Leite, R. and Brazdil, P. (2005). Predicting relative performance of classifiers from samples. In Proceedings of the 22nd International Conference on Machine Learning, ICML'05, pages 497-503, NY, USA. ACM Press.

16

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Método aos pares orientado a curvas de aprendizado parcial

Identificação da curva de aprendizado mais similar:

- A similaridade entre duas curvas de aprendizado é medida por uma adaptação do algoritmo kNN.
- A medida de distância usada entre os dataset d_i e d_j para um par de algoritmos a_p e a_q é definida pela soma de duas distâncias, uma para cada algoritmo:

$$d_{a_p, a_q}(d_i, d_j) = d_{a_p}(d_i, d_j) + d_{a_q}(d_i, d_j)$$

- Onde o primeiro termo é:

$$d_{a_p}(d_i, d_j) = \sum_{k=1}^{k_{max}} (p_{a_p, d_i, k} - p_{a_p, d_j, k})$$

- O segundo termo é calculado de maneira similar.

Leite, R. and Brazdil, P. (2005). Predicting relative performance of classifiers from samples. In Proceedings of the 22nd International Conference on Machine Learning, ICML'05, pages 497-503, NY, USA. ACM Press.

17

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Método aos pares orientado a curvas de aprendizado parcial

Realizando predições para os k datasets mais próximos:

- Assumindo-se que os k datasets mais próximos foram identificados para o algoritmo a_p usando o método descrito, o próximo passo é obter as k predições para o tamanho de amostra S_t correspondente ao tamanho do dataset alvo.
- Os autores então calculam uma média dos k valores, que é então usada como a performance predita de a_p no dataset alvo.
- Da mesma maneira calcula-se a performance predita de a_q .
- Os dois valores são comparados para determinar o melhor algoritmo.
- Nos experimentos, os autores utilizaram $k_{max} = 3$. Ou seja, a curva de aprendizado parcial inclui valores para apenas 3 amostras do dataset alvo.

Leite, R. and Brazdil, P. (2005). Predicting relative performance of classifiers from samples. In Proceedings of the 22nd International Conference on Machine Learning, ICML'05, pages 497-503, NY, USA. ACM Press.

18

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Método aos pares orientado a curvas de aprendizado parcial

Principais resultados:

- Os autores estudaram um par de algoritmos, que incluiu C5 (Quinlan, 1998) e SVM com kernel RBF.
- Os autores compararam a acurácia de classificação do método proposto (A-MDS) com a proposta clássica que usava um conjunto de meta-características (MDC).
- A performance de A-MDS usando apenas uma amostra (91 instâncias) foi melhor do que a performance obtida com MDC.
- Os autores mostraram que, usando uma curva com mais amostras, a performance de predição aumenta.

Leite, R. and Brazdil, P. (2005). Predicting relative performance of classifiers from samples. In Proceedings of the 22nd International Conference on Machine Learning, ICML'05, pages 497-503, NY, USA. ACM Press.

19

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Abordagem aos pares para um conjunto de algoritmos

- A abordagem descrita anteriormente foi incorporada em vários outros métodos que lidam com N algoritmos (ao invés de 2). Vamos descrever agora um desses trabalhos, referido como método SAM (Leite e Brazdil, 2010).
- Os passos desse método são:
 1. Seleciona um par de algoritmos de classificação e determina qual dos dois é melhor usando um método aos pares.
 2. Repete isto para todos os pares de algoritmos e gera uma ordem parcial (um grafo).
 3. Processa a ordem parcial para identificar o melhor algoritmo.
- Detalhes a seguir.

Leite, R. and Brazdil, P. (2010). Active testing strategy to predict the best classification algorithm via sampling and metalearning. In Proceedings of the 19th European Conference on Artificial Intelligence (ECAI), pages 309-314

20

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Abordagem aos pares para um conjunto de algoritmos

Selecionar um par de algoritmos e determinar o melhor:

- Este passo pode ser realizado por um teste com validação cruzada seguido de um teste de significância estatística, referido por CV_{ST} pelos autores.
- O teste retorna +1 (ou -1) se o algoritmo a_i for significativamente melhor (ou pior) que a_j . O valor 0 é retornado se não houver significância estatística na diferença de performance entre os dois.

Repete para todos os pares e gera uma ordem parcial:

- Este passo envolve aplicar o método a todos os pares possíveis e construir um grafo.
- Ao usar a saída de SAM, a aresta $a_i \rightarrow a_j$ é criada se a_i for sig. melhor que a_j .
- No exemplo da figura, vemos que o grafo gerado é um ranking quasi-linear.




Fig.: Exemplo de uma ordem parcial de 6 algoritmos de classificação (Letie e Brazdil (2010))

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Abordagem aos pares para um conjunto de algoritmos

Identificar o(s) melhor(es) algoritmo(s)

- Os autores identificaram 3 diferentes medidas de agregação da informação detalhada presente no grafo:

- W , a soma de todas as vitórias (arestas saindo)
- L , a soma de todas as derrotas (arestas entrando)
- $W - L$, a diferença entre as vitórias e as derrotas.
- Com isso pode-se construir a tabela ao lado.
- Neste exemplo, MLP é o melhor algoritmo.

Algorithm	W	L	W+L
MLP	4	0	4
LogD	3	0	3
NB	3	-1	2
J48	2	-3	-1
JRip	0	-4	-4
IB1	0	-4	-4




Fig.: Exemplo de uma ordem parcial de 6 algoritmos de classificação (Letie e Brazdil (2010))

- Desvantagem do método: O número de modelos aos pares é $(N \times (N - 1))/2$, onde N é o número de algoritmos sendo comparados. $N = 20$ implica em 190 modelos.

Leite, R. and Brazdil, P. (2010). Active testing strategy to predict the best classification algorithm via sampling and metalearning. In Proceedings of the 19th European Conference on Artificial Intelligence (ECAI), pages 309-314

Leite, R. and Brazdil, P. (2010). Active testing strategy to predict the best classification algorithm via sampling and metalearning. In Proceedings of the 19th European Conference on Artificial Intelligence (ECAI), pages 309-314

21

22

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Abordagem iterativa para condução de testes aos pares

- Ao invés de executar testes para todos os pares, a proposta de (van Rijn et al., 2015; van Rijn, 2016) é utilizar um método de busca para identificar o melhor algoritmo em potencial.
- Como consequência os testes aos pares são conduzidos sob demanda, comparando o melhor em potencial com os demais, a medida em que o método procede.
- Outra melhoria é que o método leva em conta o tempo de execução dos testes. Então testes mais rápidos são preferidos a outros mais lentos.
- O método é chamado de Pairwise Curve Comparison (PCC) e conta com esses passos:
 1. Inicializar o melhor algoritmo atual e elaborar curvas de aprendizado parcial (uma para cada algoritmo) no dataset alvo.
 2. Buscar o melhor algoritmo candidato para realizar o teste.
 3. Conduzir o teste selecionado e atualizar o melhor algoritmo atual.
 4. Repetir o processo até que uma condição de parada seja satisfeita.
- Veremos os detalhes a seguir.

van Rijn, J. N., Abdulrahman, S., Brazdil, P., and Vanschoren, J. (2015). Fast algorithm selection using learning curves. In International Symposium on Intelligent Data Analysis XIV, pages 298-309.

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Abordagem iterativa para condução de testes aos pares

Inicialização do melhor algoritmo atual (a_{best}):

- Um dos algoritmos é selecionado aleatoriamente para ser o primeiro valor de a_{best} .
- Alternativamente, poderia-se utilizar o top-1 do ranking médio dos datasets de treinamento.
- Após a inicialização, é necessário elaborar as curvas de aprendizado parcial no dataset alvo. Ou, seja, realizar testes com a_{best} em diferentes amostras do dataset alvo.
- Note que até aqui, nenhum teste é realizado no dataset alvo ao completo.

van Rijn, J. N., Abdulrahman, S., Brazdil, P., and Vanschoren, J. (2015). Fast algorithm selection using learning curves. In International Symposium on Intelligent Data Analysis XIV, pages 298-309.

23

24

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Abordagem iterativa para condução de testes aos pares

Busca pelo melhor teste aos pares:

- Aqui consideramos todos os candidatos possíveis, um por um.
- Cada um representa um competidor a_{comp} que pode substituir o atual melhor algoritmo a_{best} .
- Para determinar se a_{comp} é melhor, é necessário prever sua performance em relação a a_{best} .
- O método usa os k datasets com as curvas mais similares a a_{comp} e a_{best} para isso.
- Se a_{comp} for melhor que a_{best} nas curvas de aprendizado completas nos k datasets, então substitui-se o valor de a_{best} pelo de a_{comp} .
- O método continua iterando até que todos os algoritmos candidatos sejam considerados.

van Rijn, J. N., Abdulrahman, S., Brazdil, P., and Vanschoren, J. (2015). Fast algorithm selection using learning curves. In International Symposium on Intelligent Data Analysis XIV, pages 298–309.



25

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Abordagem iterativa para condução de testes aos pares

Melhoria para incorporar acurácia e tempo:

- Os autores mostraram que o método pode ser melhorado facilmente para incorporar o tempo de execução.
- As comparações de performance nas amostras entre a_{comp} e a_{best} podem usar a medida combinada de acurácia e tempo $A3R'$, que é uma versão simplificada da $A3R$ vista anteriormente.

$$A3R'_{a_j} = \frac{P_{a_j}^{d_i}}{(T_{a_j}^{d_i})^Q}$$

- Onde, P representa performance (ex.: acurácia), T o tempo, e Q é um fator de escala que controla a importância do tempo na equação.
- Os experimentos confirmaram a utilidade de considerar tanto a acurácia como o tempo como medidas de performance, quando o objetivo é obter rankings de classificadores.

van Rijn, J. N., Abdulrahman, S., Brazdil, P., and Vanschoren, J. (2015). Fast algorithm selection using learning curves. In International Symposium on Intelligent Data Analysis XIV, pages 298–309.



26

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Uso de árvores ART e florestas

- Sun e Pfahringer (2013) propuseram o método denominado Approximate Ranking Trees Forests para gerar predições. O método envolve duas fases:
 1. Construção de um conjunto de modelos e geração de meta-features
 2. Uso de florestas ART em conjunção com as novas meta-features para gerar as predições:

Sun, Q. and Pfahringer, B. (2013). Pairwise meta-rules for better meta-learning-based algorithm ranking. Machine Learning, 93(1):141–161



27

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Uso de árvores ART e florestas

1. Construção de um conjunto de modelos e geração de meta-features:
 - Um conjunto de meta-modelos aos pares é gerado usando um classificador baseado em regras (RIPPER). Cada meta-modelo é treinado para prever se deve ser usado algoritmo a_i ou a_j .
 - Cada meta-modelo pode usar um subconjunto de meta-features diferentes.
 - Os classificadores binários (meta-modelos) são invocados para gerar novas meta-features. Para cada regra que compõe um meta-modelo, uma meta-feature é gerada.
 - Estas novas MFs são adicionadas às tradicionais incluindo estatísticas, de teoria da informação e landmarks.

Sun, Q. and Pfahringer, B. (2013). Pairwise meta-rules for better meta-learning-based algorithm ranking. Machine Learning, 93(1):141–161



28

Utilizando classificação em nível meta

Métodos baseados em comparação aos pares

Uso de árvores ART e florestas

2. Uso de florestas ART em conjunção com as novas meta-features para gerar as predições:

- Aqui as florestas ART são treinadas no conjunto de meta-features final para gerar as predições das performances dos algoritmos. Essas podem ser interpretadas na forma de rankings.
- Mostrou-se que a performance preditiva deste método é superior à do kNN, e que ao adicionar as novas features a performance é melhorada.
- Desvantagem: todos os modelos aos pares possíveis precisam ser construídos. O método não escala bem para muitos algoritmos.

Sun, Q. and Pfahringer, B. (2013). Pairwise meta-rules for better meta-learning-based algorithm ranking. Machine Learning, 93(1):141–161



Exercício

Acesse o código:

- A) ...
- B) ...
- C) ...

Obs.: Gere tabelas e gráficos para representar seus resultados. Crie, no notebook, células textuais apresentando e discutindo esses resultados. Envie na tarefa o link para o Google Colab.

<https://github.com/amorimlb/Meta-aprendizagem-2026.1-code>

