

A escolha da técnica de escalonamento é importante para o desempenho da classificação.

Lucas BV de Amorim^{a,*}, George DC Cavalcantia, Rafael MO Cruz^c

^aCentro de Informática - Universidade Federal de Pernambuco

^bInstituto de Computação - Universidade Federal de Alagoas ^cEcole de
Technologie Supérieure, Université du Québec

Resumo

O escalonamento de conjuntos de dados, também conhecido como normalização, é uma etapa essencial de pré-processamento em um pipeline de aprendizado de máquina. Seu objetivo é ajustar as escalas dos atributos de forma que todos variem dentro da mesma faixa. Sabe-se que essa transformação melhora o desempenho de modelos de classificação, mas existem diversas técnicas de escalonamento disponíveis, e essa escolha geralmente não é feita com cuidado. Neste artigo, realizamos um amplo experimento comparando o impacto de 5 técnicas de escalonamento no desempenho de 20 algoritmos de classificação, incluindo modelos monolíticos e de ensemble, aplicando-os a 82 conjuntos de dados disponíveis publicamente com diferentes taxas de desbalanceamento. Os resultados mostram que a escolha da técnica de escalonamento é importante para o desempenho da classificação, e a diferença de desempenho entre a melhor e a pior técnica de escalonamento é relevante e estatisticamente significativa na maioria dos casos. Eles também indicam que escolher uma técnica inadequada pode ser mais prejudicial ao desempenho da classificação do que não escalonar os dados. Mostramos ainda como a variação de desempenho de um modelo de ensemble, considerando diferentes técnicas de escalonamento, tende a ser ditada pela variação de desempenho do seu modelo base. Por fim, discutimos a relação entre a sensibilidade de um modelo à escolha da técnica de escalonamento e seu desempenho, além de fornecer insights sobre sua aplicabilidade em diferentes cenários de implantação de modelos. Os resultados completos e o código-fonte dos experimentos deste artigo estão disponíveis em um repositório GitHub.¹

Palavras-chave: Classificação, Normalização, Padronização, Escalonamento
Pré-processamento, Conjunto de classificadores, Sistema de múltiplos classificadores

1. Introdução

Em uma tarefa de classificação, o escalonamento, também chamado de normalização, é usado como uma etapa essencial de pré-processamento para adequar os dados de forma que cada característica varie dentro da mesma faixa. Durante o processo de aprendizado do modelo, isso garante que as características

*Autor correspondente ¹https://github.com/amorimlb/scaling_matters

Valores com intervalos numéricos maiores ou mais amplos não dominam aqueles que variam em um intervalo menor ou mais estreito, um fenômeno que pode enviesar a análise em direção a atributos menos importantes (menos informativos) simplesmente por estarem em uma escala maior. O escalonamento do conjunto de dados é, portanto, capaz de mitigar esse fenômeno e, conseqüentemente, melhorar o desempenho da classificação.

A maioria dos pesquisadores aplica essa etapa de pré-processamento por padrão em seus fluxos de trabalho de análise, independentemente do algoritmo de classificação ou do conjunto de dados utilizado. Assim, parece que os benefícios promovidos pelo escalonamento do conjunto de dados para o desempenho da classificação são de senso comum na literatura de aprendizado de máquina. Ratificando esse senso comum, Singh et al. [1] realizaram uma breve revisão de artigos em diferentes domínios de aplicação que compararam o desempenho de classificadores treinados com dados não escalonados ao de classificadores treinados com uma técnica de escalonamento escolhida.

Os resultados confirmam que o escalonamento dos dados antes do treinamento do modelo pode levar a melhorias significativas de desempenho em comparação com dados não escalonados.

Apesar disso, estimamos que apenas 16 dos 50 artigos de classificação mais citados desde 2018, utilizando o repositório de dados KEEL[2]², mencionaram a aplicação dessa etapa de pré-processamento. Acreditamos que os 34 artigos restantes provavelmente aplicaram o escalonamento do conjunto de dados, embora não o tenham mencionado. Isso demonstra como essa etapa crucial e onipresente de pré-processamento não está recebendo a atenção merecida na literatura.

Além disso, existem diversas técnicas de escalonamento que podem ser aplicadas a um conjunto de dados e a escolha da melhor delas é, por si só, uma importante decisão metodológica. Essa decisão deve ser cuidadosamente considerada, pois foi relatado [1, 3] que escolher a técnica errada pode ser mais prejudicial ao desempenho da classificação do que não escalonar os dados.

Não obstante, apenas alguns estudos investigam como essas técnicas de escalonamento se comparam entre si em termos do desempenho de classificação resultante quando aplicadas como uma etapa de pré-processamento em diferentes algoritmos de classificação.

Alguns desses estudos concentram sua análise em apenas duas técnicas de escalonamento [4, 5], enquanto aqueles que experimentam um número maior de técnicas restringem seus testes a apenas um [1, 3] ou três algoritmos de classificação [6], como detalhamos na Seção 6. A motivação deste artigo, portanto, reside na combinação de todos esses fatores: a onipresença das técnicas de escalonamento e, ao mesmo tempo, a falta de atenção a elas na comunidade de pesquisa, juntamente com a escassez de estudos empíricos sobre seu impacto no desempenho da classificação. É por isso que concentramos nossa pesquisa em responder a questões importantes sobre como o desempenho de diferentes algoritmos de classificação varia quando os dados são escalonados com distintas técnicas de escalonamento.

Neste artigo, realizamos uma análise mais abrangente, considerando diferentes tipos de algoritmos e também um número maior de conjuntos de dados aos quais aplicamos um número relevante de técnicas de escalonamento. Ao ampliar nossas opções de métodos e conjuntos de dados, conseguimos chegar a conclusões mais generalizadas em comparação com um experimento mais limitado. Com isso, pretendemos entender se

²A lista completa desses artigos pode ser encontrada no material suplementar do repositório.

A escala afeta o desempenho da classificação e a escolha da técnica de escala causa variações significativas na magnitude dessa influência no desempenho.

Além disso, queremos saber se essas variações se comportam de maneira diferente dependendo do modelo de classificação utilizado, incluindo modelos monolíticos e de conjunto.

Os modelos de conjunto combinam as saídas de classificadores monolíticos para obter uma decisão combinada que é possivelmente melhor do que as decisões de cada classificador individual neste conjunto (por exemplo, Florestas Aleatórias, XGBoost). Para os modelos de conjunto, incluímos modelos que empregam seleção dinâmica (Seleção Dinâmica de Classificadores e Seleção Dinâmica de Conjuntos), visto que esses modelos têm apresentado resultados promissores quando comparados aos monolíticos [7], o que justifica sua inclusão em nossa investigação. Para simplificar nossa análise, incluímos apenas conjuntos homogêneos, nos quais os modelos base são instâncias de um único algoritmo de classificação.

A inclusão de modelos de conjunto em nossos experimentos também nos permite contribuir com duas outras análises importantes e inovadoras: (i) a relação entre a classificação das melhores escolhas de técnicas de escalonamento para um conjunto homogêneo e a de seu modelo base, e (ii) a relação entre a sensibilidade à escolha da técnica de escalonamento e o desempenho dos modelos, o que nos permitiu discutir como os modelos de conjunto podem ser construídos para manipular essa relação.

Além disso, analisamos como as variações de desempenho observadas devido à escolha da técnica de escalonamento se comportam ao lidar com dados que apresentam diferentes taxas de desequilíbrio (IR), visto que, em dados do mundo real, é comum haver um desequilíbrio significativo entre o número de instâncias de cada classe. Por exemplo, em problemas de diagnóstico médico ou detecção facial, quando há muito mais exemplos da classe negativa do que da classe positiva. Até o momento da redação deste artigo, não conseguimos identificar outros estudos que tenham explorado os efeitos das técnicas de escalonamento quando aplicadas a dados com diferentes IRs.

Para orientar este estudo, definimos as seguintes questões de pesquisa:

RQ1 - A escolha da técnica de escalonamento influencia o desempenho da classificação?

RQ2 - Quais modelos apresentam maiores variações de desempenho quando os conjuntos de dados são escalados com diferentes técnicas?

RQ3 - Os conjuntos homogêneos tendem a seguir o padrão de variação de desempenho apresentado pelo seu modelo base quando tratados com diferentes técnicas de escalonamento?

Para responder a essas perguntas e realizar análises adicionais, modelamos um experimento usando 82 conjuntos de dados do repositório KEEL, após pré-processá-los com cinco técnicas de escalonamento diferentes. Aplicamos 20 modelos de classificação diferentes a esses conjuntos de dados, incluindo 11 modelos monolíticos e 9 modelos de conjunto.

Os conjuntos de dados provêm de diferentes domínios, com número variável de instâncias e características, e com taxas de incidência (IRs) que variam de baixas a altas, ou seja, de virtualmente balanceadas a extremamente desbalanceadas. Utilizamos validação cruzada de 5 folds e realizamos as seguintes medições:

Desempenho da classificação de acordo com duas métricas diferentes: F1 e G-Mean.

Foram utilizados testes de hipóteses para avaliar a significância dos resultados.

Em resumo, estas são as principais contribuições deste artigo:

- Demonstra empiricamente que a escolha da técnica de escalonamento é importante para o desempenho da classificação. Isso se baseia em um amplo experimento que considerou diferentes tipos e um número relevante de algoritmos de classificação, técnicas de escalonamento e conjuntos de dados.
- Demonstra-se que existe uma relação entre a classificação das melhores escolhas de técnicas de escalonamento para um conjunto homogêneo e a classificação para seu modelo base. Essa é uma descoberta importante, pois torna menos custosa a seleção de uma técnica de escalonamento ótima para um modelo de conjunto.
- Isso demonstra que a variação de desempenho devido à escolha de diferentes técnicas de escalonamento tende a ser mais evidente para conjuntos de dados com maiores taxas de desequilíbrio.
- Analisa a relação entre a sensibilidade à escolha da técnica de escalonamento e o desempenho dos modelos, e discute como os modelos en-semble podem ser construídos para manipular essa relação.

O restante deste artigo está organizado da seguinte forma: a Seção 2 discute as diferentes técnicas de escalonamento disponíveis. A Seção 3 apresenta os algoritmos de classificação utilizados neste trabalho. A metodologia experimental é abordada na Seção 4, e os resultados e discussões são apresentados na Seção 5. A Seção 6 revisa os trabalhos relacionados à comparação das técnicas de escalonamento. Finalmente, a Seção 7 resume as lições aprendidas e a Seção 8 conclui este artigo.

2. Técnicas de escalonamento

Os dados brutos que geralmente provêm de conjuntos de dados originados no mundo real frequentemente apresentam problemas que impedem sua exploração eficaz em tarefas de aprendizado de máquina. Um dos problemas mais proeminentes é a variação na escala em que as diversas características do conjunto de dados são apresentadas. No caso do aprendizado de máquina preditivo, esse problema faz com que os algoritmos aprendam modelos menos precisos. Isso ocorre devido à tendência dos algoritmos de se basearem em características que variam em uma faixa mais ampla, ou seja, as características dominantes, mesmo que estas não sejam necessariamente as mais informativas ou decisivas para a classificação correta das instâncias de dados.

Para lidar com esse problema, técnicas de escalonamento são empregadas para adequar os dados de forma que cada característica varie dentro da mesma faixa. O escalonamento é, portanto, uma das muitas etapas de pré-processamento que geralmente precisam ser realizadas antes de aplicar um modelo de aprendizado de máquina a um conjunto de dados.

É importante destacar que, embora essas técnicas sejam mais comumente chamadas de técnicas de normalização na literatura de aprendizado de máquina [1, 3, 4, 5, 6], preferimos usar o termo escalonamento por acreditarmos que ele possui um significado mais geral. Abrange tanto métodos de normalização quanto de padronização, em sentido estrito.

Significado estatístico dessas palavras, bem como métodos de escalonamento mais simples, como o Escalonador Absoluto Máximo.

Em termos simples, as técnicas de escala mais comuns podem ser divididas em dois componentes: um termo de translação e um fator de escala. Suponha que se queira transformar um vetor x ; então, na Equação 1, cada um de seus componentes x_i é transformado em x_i , onde T representa o termo de translação e S o fator de escala. O termo de translação opera movendo os dados ao longo do eixo X , enquanto o fator de escala torna os dados mais concentrados ou dispersos horizontalmente.

$$x_i = \frac{x_i - TS}{S} \quad (1)$$

Algumas técnicas mais simples podem não incluir uma dessas duas operações mencionadas anteriormente. Por exemplo, a técnica de Centralização da Média (Equação 2) simplesmente subtrai a média do vetor de cada um de seus componentes. Nesse caso, a média do vetor é o termo translacional e nenhum escalonamento real é aplicado.

$$x_i = x_i - \bar{x} \quad (2)$$

Embora a centralização da média remova efetivamente o desvio dos dados, deslocando sua média para zero, ela não consegue equalizar as variâncias dos dados entre as diferentes características de um conjunto de dados. Técnicas mais elaboradas promovem essa equalização multiplicando os dados por um fator de escala de forma que variem dentro de um intervalo definido, por exemplo, $[-1, 1]$ ou $[0, 1]$.

As subseções a seguir apresentam cada uma das cinco técnicas de escalonamento usadas neste estudo: Standard Scaler, Min-max Scaler, Maximum Absolute Scaler, Robust Scaler e Quantile Transformer. Essas são cinco técnicas de escalonamento bem conhecidas, diversas e comumente usadas. Acreditamos que essas técnicas representam bem as técnicas mais relevantes usadas pela comunidade de aprendizado de máquina. De acordo com a literatura, essas técnicas são diversas e não redundantes [1, 3].

A Figura 1 apresenta exemplos em que essas técnicas escalam pares de atributos, fornecendo um feedback visual de como elas funcionam. Cada coluna da figura corresponde a um exemplo. A distribuição original dos dados é sempre mostrada no gráfico superior. Na Figura 1a, ambas as variáveis foram geradas aleatoriamente para seguir distribuições normais com médias e variâncias escolhidas. Precisamente, se representarmos nossa variável normal gerada aleatoriamente como $x_1 \sim N(\mu, \sigma^2, n)$, onde μ é sua média, σ^2 sua variância e n é o tamanho da amostra, então: $x_1 \sim N(10, 4, 1000)$ e $x_2 \sim N(50, 4, 1000)$. Aqui, a intenção é observar como as técnicas de escala lidam com variáveis em lados opostos do eixo X .

Na Figura 1b, as duas variáveis também foram geradas aleatoriamente para seguir distribuições normais, mas 25 outliers foram adicionados a x_2 próximos ao valor 100. Mais precisamente: $x_1 \sim N(10, 4, 1000)$ e $x_2 \sim N(50, 4, 975) + N(100, 4, 25)$. Esta figura mostra como os efeitos das técnicas de escalonamento em uma variável que apresenta outliers se comparam aos seus efeitos em uma variável sem outliers.

Finalmente, a Figura 1c mostra os efeitos das técnicas em atributos com diferentes formatos de distribuição: Enquanto x_1 é, similar às figuras anteriores ($x_1 \sim$

$N(10, 4, 1000)$), x_2 é uma amostra gerada aleatoriamente a partir de uma distribuição uniforme no intervalo $[-3, 5]$, com um tamanho de amostra de 1000. O objetivo desta figura é mostrar como cada técnica manipula os formatos das distribuições.

2.1. Escalar padrão

A técnica Standard Scaler, que implementa a normalização do escore Z, padroniza os atributos subtraindo sua média de cada valor e dividindo o resultado pelo desvio padrão s do atributo, resultando em uma distribuição com média zero e variância unitária. Seja $\bar{x}$ a média da variável x , um valor x_i é transformado (escalado) em x por meio da Equação 3.

$$x_i = \frac{x_i - \bar{x}}{s} \quad (3)$$

Neste caso, o termo de translação é a média amostral do atributo, enquanto o fator de escala é o seu desvio padrão. Uma vantagem desta técnica é que ela pode transformar atributos com valores positivos e negativos em uma distribuição muito semelhante, como pode ser visto na Figura 1a. No entanto, na presença de outliers, ela torna a distribuição final dos inliers muito estreita quando comparada à de um atributo sem outliers (Figura 1b).

Variações dessa técnica são o Escalonamento de Pareto [8] (Eq. 4) e o escalonamento de Estabilidade Variável (Vast) [9] (Eq. 5). Eles alteram o fator de escala, tornando a distribuição resultante mais ampla. Dessa forma, reduzem a importância dos outliers, mas não são totalmente imunes a eles.

$$x_i = \frac{x_i - \bar{x}}{s} \quad (4)$$

$$x_i = \frac{x_i - \bar{x}}{s} \quad (5)$$

2.2. Escalar Min-Max

O Min-max Scaler altera a escala de um atributo e desloca seus valores ao longo do eixo X para que o atributo transformado fique dentro do intervalo $[0, 1]$, de acordo com a Equação 6.

$$x_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (6)$$

Nessa técnica, o fator de escala consiste na amplitude do atributo, e o termo de translação é seu valor mínimo. Dessa forma, essa técnica garante um novo mínimo de zero e um novo máximo de um. Para atributos que não apresentam outliers, o Min-max Scaler tem um efeito similar ao Standard Scaler. Contudo, no caso deste último, a distribuição resultante estará em uma faixa menos estritamente definida, como pode ser observado na Figura 1a. Por outro lado, quando os dados apresentam outliers, essa técnica não consegue equalizar as médias e variâncias das distribuições (veja a Figura 1b) e, portanto, geralmente não é adequada para um pipeline de aprendizado de máquina.




Figura 1: Efeitos das técnicas de escala selecionadas quando fornecidas como entrada: (a) variáveis com distribuição normal, com médias opostas e sem outliers, (b) variáveis com distribuição normal onde x2 apresenta outliers e (c) variáveis com diferentes formatos de distribuição: x1 tem uma distribuição normal e x2 tem uma distribuição uniforme.

O escalar Min-max pode ser generalizado na Equação 7 para permitir a definição do intervalo resultante como $[a, b]$ em vez de $[0, 1]$. De fato, notamos que pesquisadores de aprendizado de máquina frequentemente usam essa segunda forma para obter um intervalo $[-1, 1]$.

$$x_i = \frac{(x_i - x_{\min})(b - a)}{x_{\max} - x_{\min}} + a \quad (7)$$

2.3. Escalar Absoluto Máximo

O Maximum Absolute Scaler modifica a escala de um atributo simplesmente dividindo cada exemplo pelo valor absoluto máximo do atributo, como na Equação 8.

$$x_i = \frac{x_i}{\max(|x|)} \quad (8)$$

Assim, essa técnica é sensível a valores discrepantes, como pode ser visto na Figura 1b, onde x_2 é transformado em uma distribuição muito mais estreita do que x_1 . Além disso, notamos na Figura 1a que, como essa técnica de escalonamento não inclui um termo de translação, ela não consegue igualar as médias do atributo.

2.4. Escalador Robusto

As três técnicas de escalonamento anteriores são muito sensíveis à presença de outliers, uma vez que essas transformações dependem da média ou dos valores mínimo e máximo de cada variável. O Robust Scaler busca mitigar os efeitos dos outliers centrando os dados em torno da mediana (segundo quartil de x , $Q_2(x)$) e escalonando-os de acordo com o intervalo interquartil, que é a magnitude da diferença entre o primeiro quartil $Q_1(x)$ e o terceiro quartil $Q_3(x)$ de x , conforme mostrado na Equação 9.

$$x_i = \frac{x_i - Q_2(x)}{Q_3(x) - Q_1(x)} \quad (9)$$

A Figura 1b mostra que essa técnica é eficaz para equalizar as variâncias entre os diferentes atributos, mesmo quando um deles apresenta valores discrepantes. Isso ocorre porque, ao usar o intervalo interquartil como fator de escala, a presença dos valores discrepantes é desconsiderada, uma vez que eles se encontram fora desse intervalo.

2.5. Transformador de Quantis

Essa técnica de escalonamento faz parte de uma família de técnicas que realizam uma transformação não linear nos dados, em oposição às técnicas discutidas anteriormente. Ela é capaz de alterar a forma da distribuição original do atributo, o que pode ser particularmente útil, visto que há evidências de que transformar atributos para que sigam uma distribuição semelhante à gaussiana pode beneficiar o desempenho da classificação [10]. A técnica Quantile Transformer transforma um atributo usando suas informações de quantis (empregando uma função quantílica) e

Aplica todos os atributos à mesma distribuição desejada, uniforme ou normal. Na Figura 1, definimos a distribuição de saída como 'normal'. É também uma técnica robusta, pois não é sensível a valores discrepantes.

Esta transformação é aplicada a cada atributo independentemente da seguinte forma: Primeiro, a função de distribuição cumulativa do atributo é estimada e usada para mapear os valores originais para uma distribuição uniforme. Em seguida, os valores obtidos são mapeados para a distribuição de saída desejada usando a função quantil associada. Novos valores que ficam fora do intervalo de saída são mapeados para os limites da distribuição de saída [11].

Observe na Figura 1 que o Quantile Transformer é a única técnica de escalonamento capaz de fornecer distribuições resultantes consistentemente semelhantes, independentemente dos atributos originais fornecidos como entradas. Pode-se observar na Figura 1c que essa técnica foi capaz de adequar o atributo x^2 , alterando sua distribuição para que corresponda a uma distribuição normal padrão, com média zero e variância unitária.

Isso promove uma melhor comparabilidade de atributos que anteriormente possuíam escalas e formatos de distribuição diferentes. Contudo, por se tratar de uma transformação não linear, pode distorcer correlações lineares entre variáveis medidas na mesma escala.

3. Algoritmos de Classificação

Para avaliar as técnicas de escalonamento em uma ampla gama de algoritmos de classificação, selecionamos modelos monolíticos e de conjunto abrangendo oito subcategorias diferentes. A lista completa, juntamente com os parâmetros relevantes de cada modelo, é apresentada na Tabela 1. Nosso objetivo é realizar uma análise cujos resultados possam ser generalizados para uma ampla variedade de algoritmos de classificação.

Com isso em mente, selecionamos modelos monolíticos das seguintes subcategorias: baseados em instâncias, probabilísticos, análise discriminante, baseados em regras e redes neurais. Para os modelos de conjunto, os algoritmos estão distribuídos entre estas três subcategorias: estáticos, DCS e DES. Optamos por incluir modelos de conjunto em nossa análise porque (i) esses métodos, especialmente DCS e DES, mostraram-se mais promissores do que modelos monolíticos em diversos cenários [7]; (ii) assumimos que, devido ao efeito da combinação de vários classificadores, essas técnicas podem ser menos sensíveis a mudanças nos dados do que os modelos monolíticos. Além disso, não encontramos na literatura nenhuma análise sobre como esses algoritmos se comportam quando submetidos a diferentes técnicas de escalonamento.

3.1. Modelos Monolíticos

3.1.1. Algoritmos baseados em instâncias

Os algoritmos baseados em instâncias dependem de um subconjunto específico de instâncias, em vez de um modelo que represente o conjunto completo, para classificar cada instância de consulta. Por exemplo, no caso dos classificadores de vizinhos mais próximos [12], o algoritmo usa os pontos de dados de treinamento mais próximos de uma instância de consulta no espaço de características para determinar sua classe.

Este artigo inclui os seguintes algoritmos baseados em instâncias nos experimentos: k-Nearest Neighbors (KNN), GLVQ [13] e SVM [14]. Para todos

Tabela 1: Parâmetros utilizados para construir os modelos de classificação. Outros parâmetros não listados foram deixados como padrão de acordo com suas respectivas bibliotecas. DCS - Seleção Dinâmica de Classificador, DES - Seleção Dinâmica de Conjuntos. Os últimos cinco modelos herdaram seus conjuntos de dados do Bagging. modelo estático listado acima deles.

Gato. Subgato.	Nome	Modelo	Parâmetros	Biblioteca
Monolítico	Baseado em instâncias	Máquina de Vetores de Suporte (SVM) com kernel linear = 'linear'		sklearn v0.23.1
		Máquina de Vetores de Suporte (SVM) com kernel RBF = 'rbf', k-		sklearn v0.23.1
		Vizinhos Mais Próximos (KNN) com n vizinhos = 5 e n tarefas = -1.	-	sklearn v0.23.1
		Aprendizagem generalizada GLVQ	protótipos por classe=1, iterações máximas=2500,	sklearn lmq v1.1.0
	Probabilístico	Quantização vetorial gtol=1e-05, beta=2		
		Gaussian Naive Bayes GNB		sklearn v0.23.1
	Discriminante análise	Processo Gaussiano	kernel = 1.0 RBF(1.0),	sklearn v0.23.1
		Discriminante Linear	LDA	solucionador='svd', tolerância=0.0001
		Análise Quadrático	QDA	tolerância=0.0001
		Análise Discriminante		sklearn v0.23.1
Conjunto	Baseado em regras	Árvore de decisão	DT	critério='gini', divisor='melhor',
		Perceptron	Percepção	alfa=0.0001, iterações máximas=1000, tolerância=0.001,
	Neural Redes	Perceptron Multicamadas (MLP)		ativação='relu', solucionador='adam', alfa=1e-5,
			tamanhos da camada oculta=[5,	sklearn v0.23.1
	Estático	Gradiente extremo	XGBoost	2)-n estimadores=100, tipo de importância='ganho',
		Aumentando Florestas Aleatórias	RF	método de árvore=auto
		AdaBoost	AdaBoost	n estimadores=100, critério='gini' n
				estimadores=100, estimador base=
	DCS	ensacamento	ensacamento	DecisionTreeClassifier(max depth=1) n
		Visão geral local	OLA	estimators=100, base estimator=Perceptron sklearn v0.23.1
		Precisão (OLA)		classificadores de pool=[Bagging pool]
		Aula local		deslib v0.3.5
		Precisão (LCA)		classificadores de pool=[Bagging pool]
		Classificador Múltiplo	MCB	deslib v0.3.5
		Comportamento (MCB)		classificadores de pool=[Bagging pool]
		k-Oráculos Mais Próximos		
	DES	Eliminar (KNORA-E) k-	Classificadores de pool-KNORAE=[Bagging pool], k=7	deslib v0.3.5
		Oráculos Mais Próximos		
		União (KNORA-U)	Classificadores de pool-KNORAU=[Bagging pool], k=7	deslib v0.3.5

Desses algoritmos, utilizamos a implementação fornecida pelo Scikit-learn.

Biblioteca Python (sklearn) [15].

O algoritmo KNN classifica uma nova instância (de consulta) consultando primeiro a rótulos de k instâncias de treinamento que são mais próximas da instância de consulta e então Atribuir o rótulo mais comum à instância da consulta. O algoritmo GLVQ, que é uma generalização do algoritmo LVQ, primeiro aprende protótipos para representar as instâncias e depois classifica as instâncias de consulta com base em suas distâncias. aos protótipos. O algoritmo SVM tenta maximizar as distâncias entre instâncias de classes diferentes são criadas através da criação de um hiperplano que divide as classes. ao mesmo tempo que se mantém equidistante das instâncias mais "marginais" de ambas as classes, o vetores de suporte. Uma instância de consulta é atribuída a uma classe de acordo com sua posição em relação ao hiperplano. Observe que se pode dizer que GLVQ e SVM não são puramente baseadas em instâncias, já que ambas aprendem uma abstração do instâncias.

3.1.2. Algoritmos probabilísticos

Os algoritmos probabilísticos baseiam-se em modelos de probabilidade para calcular a probabilidade de uma instância específica pertencer a uma classe. Os classificadores Naive Bayes são bons exemplos disso. representam esta categoria. O Naive Bayes utiliza o teorema de Bayes com a suposição "ingênua" de independência condicional entre os pares de atributos, dado um classe específica. Apesar dessa simplificação, eles se provaram classificadores úteis. mesmo quando essa suposição não se verifica [16]. Embora não sejam precisos estimadores de probabilidade neste caso [17]. Uma implementação de tais classificadores

é o Gaussian Naive Bayes (GNB), que assume a probabilidade das características como uma distribuição Gaussiana. Este artigo inclui o GNB e outro tipo de classificador probabilístico, o classificador de Processo Gaussiano (GP) [18].

3.1.3. Análise Discriminante A análise

discriminante é uma família de métodos que visa encontrar superfícies de decisão que sejam mais eficazes na separação das classes das instâncias de dados no espaço de características. A Análise Discriminante Linear (LDA) e a Análise Discriminante Quadrática (QDA) estão incluídas em nossos experimentos. Na LDA, o algoritmo busca superfícies de decisão lineares, enquanto na QDA, busca superfícies de decisão quadráticas. Esses métodos também são comumente usados para redução de dimensionalidade.

3.1.4. Algoritmos baseados em regras

Classificadores baseados em regras são aqueles que utilizam regras SE-ENTÃO para predição de classe [19]. Dessa forma, podemos considerar a Árvore de Decisão como um modelo baseado em regras, pois ela aprende essas regras, com as quais constrói a árvore. Neste artigo, incluímos o classificador Árvore de Decisão (DT) incluído no sklearn, que implementa uma versão otimizada do algoritmo de Árvores de Classificação e Regressão (CART) [20].

3.1.5. Redes Neurais

As Redes Neurais Artificiais (RNAs), também chamadas simplesmente de “Redes Neurais”, são algoritmos inspirados nos mecanismos presentes nas redes neurais biológicas em nossos cérebros. As RNAs contêm unidades computacionais, chamadas neurônios, conectadas por meio de pesos, que imitam o papel da força das conexões sinápticas nas redes neurais biológicas [21].

A arquitetura de RNA mais simples é o Perceptron de Camada Única, ou simplesmente Perceptron. Ele contém uma única camada de entrada e um nó de saída. Similarmente ao LDA, busca uma superfície de decisão linear que melhor separe as classes de um problema. Os Perceptrons Multicamadas são modelos mais complexos que contêm múltiplas camadas computacionais. Cada camada alimenta suas saídas para as entradas da camada seguinte, o que permite cálculos mais complexos. As superfícies de decisão resultantes são não lineares e, portanto, mais flexíveis, a ponto de poderem até mesmo levar ao sobreajuste (overfitting), que pode ser resolvido com um melhor ajuste dos hiperparâmetros do modelo. Este artigo inclui tanto um perceptron de camada única (Perceptron) quanto um perceptron multicamadas (MLP).

3.2. Modelos de Conjunto

Os modelos de conjunto, também chamados de Sistemas de Classificadores Múltiplos ou Comitês de Classificadores, integram as decisões de um conjunto (conjunto) de classificadores com o objetivo de obter uma decisão combinada que seja melhor do que as decisões de cada classificador individual no conjunto. Estudos teóricos e empíricos mostraram que um conjunto é tipicamente mais preciso do que um classificador individual [22].

Os classificadores dentro de um conjunto são chamados de classificadores base. A maioria dos modelos de conjunto usa um único algoritmo de classificação para gerar todos os classificadores base.

Os conjuntos são chamados de conjuntos homogêneos. Por outro lado, quando os classificadores base são gerados por múltiplos métodos, o conjunto é chamado de conjunto heterogêneo. Por uma questão de simplicidade, incluímos apenas conjuntos homogêneos neste trabalho.

Quando se trata de como as decisões dos múltiplos classificadores base são combinadas, existem basicamente duas categorias: ensembles estáticos e dinâmicos. Os ensembles estáticos geralmente geram suas decisões combinando as saídas dos classificadores base por meio de uma regra de votação majoritária, onde a decisão mais frequente é escolhida, ou uma variação desse mecanismo, como a votação majoritária ponderada [23, 24]. Os modelos de conjunto mais conhecidos e utilizados pertencem à categoria de conjuntos estáticos.

Os ensembles dinâmicos selecionam um único classificador (DCS - Seleção Dinâmica de Classificadores) ou um subconjunto do ensemble original (DES - Seleção Dinâmica de Ensembles) para rotular uma instância de consulta. Em ambos os casos, os modelos consideram a região local onde a instância de consulta se encontra, definida por suas k instâncias de treinamento mais próximas, e tentam selecionar o(s) classificador(es) base com melhor desempenho nessa região. Essa região local é chamada de Região de Competência (RoC) da consulta de entrada.

Os ensembles dinâmicos têm se mostrado muito promissores para diversos cenários [7], tornando esses modelos uma adição valiosa ao nosso arsenal. Além disso, não existem estudos prévios sobre como seu desempenho varia sob diferentes técnicas de escalonamento, o que é uma investigação interessante, visto que, em sua fase de seleção, esses métodos utilizam a noção de uma região local de competência, que é suscetível a mudanças devido ao escalonamento do conjunto de dados. Este artigo inclui nove modelos de ensemble, que descrevemos a seguir. Como pode ser visto na Tabela 1, para os modelos de ensemble, utilizamos as implementações fornecidas pelas bibliotecas Python Scikit-learn [15], XGBoost [25] e DESlib [26].

3.2.1. Conjuntos Estáticos

Neste artigo, são considerados quatro conjuntos estáticos que representam as abordagens mais comuns.

Bagging, um acrônimo para Bootstrap AGGregating, foi introduzido por Leo Breiman, em 1996 [27]. Sua ideia é criar um conjunto composto por diversos classificadores base, fornecendo-lhes réplicas bootstrap do conjunto de treinamento [22]. Em outras palavras, cada classificador base é treinado em um subconjunto diferente dos dados rotulados, geralmente gerado por amostragem aleatória com reposição. As saídas dos vários classificadores base são combinadas por votação majoritária.

Florestas Aleatórias Também introduzidas por Leo Breiman, em 2001 [28], as Florestas Aleatórias são uma extensão do Bagging, embora especificamente projetadas para conjuntos de árvores de decisão, onde a principal diferença é que incorporam a seleção aleatória de características [22]. Ao construir cada árvore de decisão no conjunto, além de fornecer a elas uma cópia bootstrap do conjunto de treinamento, o algoritmo realiza o procedimento convencional de divisão da árvore de decisão, mas dentro de um subconjunto aleatório das características.

AdaBoost, cujo nome deriva de ADaptive BOOSTing, é uma técnica de boosting introduzida por Freund e Schapire em 1997 [29]. Essa técnica funciona adicionando iterativamente um classificador por vez. Cada classificador é treinado em um subconjunto selecionado das instâncias de treinamento, onde a distribuição de amostragem começa uniforme, mas muda a cada iteração, atribuindo probabilidades de seleção mais altas às instâncias que foram classificadas incorretamente na iteração anterior [22]. Dessa forma, o algoritmo reúne classificadores cujo treinamento é cada vez mais focado nas instâncias mais difíceis do conjunto de treinamento.

O XGBoost fornece otimizações sobre o algoritmo GBM (Gradient Boosting Machine) original [30], visando torná-lo mais escalável e preciso. O Gradient Boosting Machine, ou Gradient Tree Boosting, por sua vez, pode ser entendido como uma generalização do AdaBoost. Ele também adiciona gradualmente classificadores (neste caso, Árvores de Decisão) ao conjunto. A principal diferença reside em como ele impulsiona os classificadores base: em vez de atribuir pesos maiores a instâncias mais difíceis, o GBM minimiza uma função de perda diferenciável que pode ser definida pelo usuário. Uma árvore é adicionada ao conjunto se reduzir a perda. O XGBoost adiciona regularização para controlar o sobreajuste, processamento paralelo, maneiras de lidar com dados esparsos e outras modificações que melhoram seu desempenho em relação aos métodos de boosting anteriores [25].

3.2.2. Conjuntos Dinâmicos

Nossos experimentos incluem cinco conjuntos dinâmicos: 3 DCS e 2 DES. estratégias.

A Precisão Local Global (OLA) é um método DCS simples que avalia a competência (precisão) de cada classificador base na curva ROC da instância de consulta e, em seguida, seleciona aquele que apresenta a maior precisão. A saída do classificador selecionado determina a decisão do conjunto [31].

A Precisão de Classe Local (LCA) é um método DCS que avalia a competência local de cada classificador base em relação a uma classe específica. Dado que um classificador base prevê a classe w_l para a instância de consulta, sua competência é a porcentagem de amostras de treinamento no RoC rotuladas como w_l que ele prevê corretamente como w_l . O classificador mais competente determina então a saída do conjunto [31].

Comportamento de Classificadores Múltiplos (MCB) O MCB é um método DCS onde a RoC é definida tanto pela abordagem kNN quanto pelo método de conhecimento comportamental (BKS) [32]. Primeiro, as saídas de todos os classificadores base são calculadas para todas as instâncias de treinamento. Em seguida, uma RoC inicial é definida selecionando os k vizinhos mais próximos. Essa RoC é então filtrada selecionando apenas as instâncias que são suficientemente semelhantes à instância de consulta com base no método BKS. O método BKS mede a similaridade entre as decisões de múltiplos classificadores quando um par de instâncias é fornecido como entrada. Quando

Se essa similaridade for maior que um determinado limiar, a instância é selecionada para integrar o RoC. Após definir o RoC, o nível de competência de um classificador é calculado de acordo com o OLA. No final, o classificador base mais competente determina a saída do conjunto se for melhor que os outros classificadores por um determinado limiar; caso contrário, aplica-se uma regra de votação majoritária [33].

O método k-Nearest Oracles Eliminate (KNORA-E) faz parte da família KNORA de métodos DES propostos por Ko et al. [34], que é inspirada no conceito de Oracle [35]. Um Oracle é um método abstrato de seleção de classificadores que sempre seleciona os classificadores que retornam a saída correta, se tais classificadores existirem.

No método KNORA-E, um classificador é considerado competente em uma determinada região de competência (RoC) se atingir desempenho perfeito para as instâncias dentro dessa região. Tal classificador é conhecido como oráculo local. Todos os oráculos locais são selecionados. Caso não existam oráculos locais na RoC, o número de vizinhos que a compõem é reduzido iterativamente, removendo-se o vizinho mais distante, até que pelo menos um classificador atinja desempenho perfeito.

Quando nenhum oráculo local é encontrado, todo o conjunto (conjunto inicial) é usado para a classificação. Em ambos os casos, as saídas do conjunto resultante são combinadas usando a regra de votação majoritária.

União de Oráculos k-Mais Próximos (KNORA-U) O método KNORA-U, por sua vez, seleciona todos os classificadores que produzem a saída correta para pelo menos uma instância na RoC. Para cada instância classificada corretamente na RoC, o classificador base pode enviar um voto para classificar a instância de consulta. Os votos de todos os classificadores selecionados são combinados para produzir a saída, que será a classe com mais votos.

4. Metodologia Experimental

Para este experimento, aplicamos as cinco técnicas de escalonamento selecionadas a cada um dos 82 conjuntos de dados originais escolhidos para o estudo, criando 5 variantes adicionais de cada conjunto de dados. Em seguida, aplicamos 20 modelos de classificação diferentes a esses conjuntos de dados. Para simplificar, optamos por não balancear os conjuntos de dados, mantendo-os com suas proporções originais de desequilíbrio de classes. O desempenho da classificação foi medido de acordo com duas métricas diferentes: F1 e G-Mean. Escolhemos essas métricas porque elas consideram a natureza desbalanceada dos conjuntos de dados [36]. A seleção das técnicas de escalonamento e dos algoritmos de classificação priorizou a diversidade e a popularidade dos métodos na comunidade de aprendizado de máquina. No caso das técnicas de escalonamento, evitamos incluir técnicas redundantes, visto que em trabalhos anteriores que utilizaram um número maior de técnicas, foi relatado que muitas delas produziram resultados semelhantes para a maioria dos conjuntos de dados [1, 3].

O código-fonte do experimento, todos os conjuntos de dados utilizados e os resultados completos. As tabelas estão disponíveis no repositório do GitHub mencionado anteriormente.

4.1. Seleção de conjuntos de

dados Para permitir a reprodutibilidade deste estudo, utilizamos múltiplos conjuntos de dados disponíveis publicamente, apresentando uma ampla gama de valores de IR obtidos do repositório de conjuntos de dados KEEL [2]. Esses conjuntos de dados do mundo real foram originalmente publicados no repositório UCI Machine Learning, que contém uma coleção de conjuntos de dados frequentemente utilizados por pesquisadores de aprendizado de máquina para a análise empírica de algoritmos [37]. O repositório UCI também contém conjuntos de dados artificiais e geradores de dados, mas foi devido à sua ampla seleção de conjuntos de dados do mundo real que se tornou uma das fontes mais populares para estudos empíricos de aprendizado de máquina.

Os conjuntos de dados que utilizamos foram pré-processados pela equipe KEEL de forma que os problemas de classificação múltipla fossem transformados em problemas binários e também divididos em arquivos visando seu uso com uma validação cruzada estratificada de 5 partes (que empregamos). Dessa forma, como os conjuntos de dados já estão pré-divididos, qualquer pesquisador que utilizar esses dados usará exatamente as mesmas divisões. Isso também promove a reprodutibilidade da pesquisa.

Primeiramente, selecionamos todos os 91 conjuntos de dados disponíveis no KEEL que são binários e apresentam diferentes taxas de desequilíbrio. Em seguida, selecionamos aqueles com no máximo 30% de atributos categóricos (de forma que esses atributos não exerçam influência significativa nos resultados, visto que estamos interessados nos efeitos das técnicas de escalonamento, que se aplicam apenas a dados numéricos), resultando em 82 conjuntos de dados, conforme descrito na Tabela 2. Esta tabela mostra os nomes dos conjuntos de dados, juntamente com o número de atributos numéricos e categóricos, a contagem de classes (ou seja, quantas instâncias pertencem a cada classe) e, finalmente, a taxa de desequilíbrio (IR), que é a proporção entre o número de instâncias da classe majoritária e o da classe minoritária. A tabela está ordenada de acordo com a taxa de desequilíbrio.

Os conjuntos de dados representam problemas de uma ampla gama de domínios. Há conjuntos de dados sobre identificação de vidro (glass), análises médicas (pima, wisconsin, haberman, cleveland, dermatology), identificação de plantas (iris), reconhecimento de fala (vowel), biologia molecular e celular (yeast, e. coli), reconhecimento de imagem (vehicle, led7digit), aeronáutica (shuttle) e outros.

4.2. Escalonamento dos

Conjuntos de Dados Antes de aplicar as técnicas de escalonamento, duas outras tarefas comuns de pré-processamento foram realizadas: limpeza de strings (remoção e padronização) e codificação one-hot, aplicadas aos atributos categóricos. Na etapa de limpeza de strings, todos os nomes e valores das classes foram padronizados em cada conjunto de dados, removendo espaços em branco extras e corrigindo erros de digitação. O mesmo procedimento foi aplicado aos valores dos atributos categóricos, para evitar o reconhecimento de valores com erros ortográficos como novas categorias. Na etapa de codificação one-hot, cada atributo categórico é substituído por $n + 1$ colunas binárias, onde n é o número de valores únicos do atributo. Dessa forma, a combinação dos bits nas $n + 1$ colunas binárias codifica numericamente os n valores categóricos possíveis do atributo.

Isso garante que o conjunto de dados possa ser processado por algoritmos que não conseguem lidar com atributos não numéricos.

Quanto à escala dos dados, que é a principal variável independente neste estudo, implementamos o seguinte procedimento: Criamos cinco cópias de cada um dos

Tabela 2: Descrição dos conjuntos de dados. Nota: Num. attrib. é o número de atributos numéricos. enquanto Categ. attrib. é o número de atributos categóricos.

#	Conjunto de dados nome	Num. atributo.	Categoria. atributo.	Aula contagens	IR	#	Conjunto de dados nome	Num. atributo.	Categoria. atributo.	Aula contagens	IR
	vidro1	9	0	(138, 76)	1.82		42 vidro-0-1-4-6 vs 2 43	9	0	(188, 17)	11.06
1 2	ecoli-0 vs 1	7	0	(143, 77)	1.86		vidro2 44	9	0	(197, 17)	11.59
	wisconsin	9	0	(444, 239)	1.86		ecoli-0-1-4-7 vs 5-6 45	6	0	(307, 25)	12.28
3 4	pima 5	8	0	(268, 500)	1.87		cleveland-0 vs 4	13	0	(160, 13)	12.31
	iris0	4	0	(50, 100)	2.00		46 ecoli-0-1-4-6 vs 5	6	0	(260, 20)	13.00
6	vidro0	9	0	(70, 144)	2.06		47 shuttle-c0-vs-c4	9	0	(1706, 123)	13.87
7		8	0	(1055, 429)	2.46		48 levedura-1 vs 7 49	7	0	(429, 30)	14.30
	levedura1 8 veículo	3	0	(225, 81)	2.78		vidro4 50 e.	9	0	(201, 13)	15.46
	haberman2	18	0	(628, 218)	2.88		col4	7	0	(316, 20)	15.80
9 10	veiculo1 11	18	0	(629, 217)	2.90		51 blocos-de-página-1-3 vs 4 52	10	0	(444, 28)	15.86
	veiculo3 12	18	0	(634, 212)	2.99		abalone9-18 53	7	1	(689, 42)	16.40
	vidro-0-1-2-3 vs 4-5-6 13 veículo0	9	0	(163, 51)	3.20		dermatologia 6 54	34	0	(338, 20)	16.90
14	ecoli 15	18	0	(199, 647)	3.25		vidro-0-1-6 vs 5 55	9	0	(175, 9)	19.44
	nova-tireoide1	7	0	(259, 77)	3.36		lançadeira-c2-vs-c4 56	9	0	(6, 123)	20.50
16	ecoli2	5	0	(180, 35)	5.14		lançadeira-6 vs 2-3 57	9	0	(220, 10)	22.00
		7	0	(284, 52)	5.46		levedura-1-4-5-8 vs 7 58	8	0	(663, 30)	22.10
17	segmento0 18	19	0	(1879, 329)	6.02		vidro5 59	9	0	(205, 9)	22.78
	vidro6 19	9	0	(185, 29)	6.38		levedura-2 vs 8 60	8	0	(462, 20)	23.10
	levedura3 20	8	0	(1321, 163)	8.10		levedura4 61	8	0	(1433, 51)	28.10
	e. coli3	7	0	(301, 35)	8.60		qualidade-do-vinho-tinto-4 62	11	0	(1546, 53)	29.17
21	blocos-de-página0	10	0	(4913, 559)	8.79		póquer-9 vs 7 63	10	0	(236, 8)	29.50
22	ecoli-0-3-4 vs 5 23	7	0	(180, 20)	9.00		levedura-1-2-8-9 vs 7 64	8	0	(917, 30)	30.57
	levedura-2 vs 4 24	8	0	(463, 51)	9.08		abalone-3 vs 11 65	7	1	(15, 487)	32.47
	ecoli-0-6-7 vs 5 25	7	0	(200, 22)	9.09		qualidade-do-vinho-branco-9 vs 4 66	11	0	(163, 5)	32.60
	ecoli-0-2-3-4 vs 5 26	7	0	(182, 20)	9.10		levedura5 67	8	0	(1440, 44)	32.73
	vidro-0-1-5 vs 2 27	9	0	(155, 17)	9.12		qualidade-do-vinho-tinto-8 vs 6 68	11	0	(638, 18)	35.44
	levedura-0-3-5-9 vs 7-8-28	8	0	(456, 50)	9.12		ecoli-0-1-3-7 vs 2-6 69	7	0	(274, 7)	39.14
	levedura-0-2-5-6 vs 3-7-8-9-29	8	0	(905, 99)	9.14		abalone-17 vs 7-8-9-10	7	1	(2280, 58)	39.31
	ecoli-0-4-6 vs 5	6	0	(183, 20)	9.15		70 abalone-21 vs 8	7	1	(14, 567)	40.50
30	ecoli-0-1 vs 2-3-5	7	0	(220, 24)	9.17		71 levedura6	8	0	(1449, 35)	41.40
31	ecoli-0-2-6-7 vs 3-5	7	0	(202, 22)	9.18		72 qualidade do vinho branco 3 vs 7	11	0	(880, 20)	44.00
32	vidro-0-4 vs 5 33 e.	9	0	(83, 9)	9.22		73 qualidade do vinho tinto 8 vs 6 7	11	0	(837, 18)	46.50
	ecoli-0-3-4-6 vs 5 34 e.	7	0	(185, 20)	9.25		74 abalone 19 vs 10-11-12-13 7	1	32	(1590, 49)	49.69
	ecoli-0-3-4-7 vs 5-6 35	7	0	(232, 25)	9.28		75 winequality-white-3-9 vs 5 11 76 poker-8-9 vs	0		(1457, 25)	58.28
	levedura-0-5-6-7-9 vs 4 8 36 vogal0 13 37 e.	0		(477, 51)	9.35		6 10 77 shuttle-2 vs 5 9 78 winequality-red-3 vs 5	0		(1460, 25)	58.40
	ecoli-0-6-7 vs 5 6 38 vidro-0-1-6 vs 2 9 39 e.	0		(90, 898)	9.98		11 79 abalone-20 vs 8-9-10 7 80 poker-8-9 vs 5	0		(3267, 49)	66.67
	ecoli-0-1-4-7 vs 2-3-5-6 7 40 led7digit0-0-2-4-5-6-7-8-9	0		(200, 20)	10.00		10 81 poker-8 vs 6 10 82 abalone19	0		(681, 10)	68.10
	vs 1 7 41 e. ecoli-0-1 vs 5 6	0		(175, 17)	10.29			1		(1890, 26)	72.69
		0		(307, 29)	10.59			0		(2050, 25)	82.00
		0		(406, 37)	10.97			0		(1460, 17)	85.88
		0		(220, 20)	11.00			7	1	(4142, 32)	129.44

Em seguida, partimos de 82 conjuntos de dados originais e aplicamos a cada uma das cinco cópias uma das técnicas de escalonamento selecionadas: Standard Scaler, Min-max Scaler e Maximum Absolute.

Scaler, Robust Scaler e Quantile Transformer. Também mantivemos uma versão inalterada.

Cópia dos conjuntos de dados (não escalonados) para servir como linha de base.

É importante registrar isso, a fim de evitar vazamento de informações de o conjunto de testes na fase de treinamento, um problema conhecido como viés de antecipação, Cada uma das cinco dobras em um conjunto de dados foi dimensionada independentemente de acordo com o parâmetros obtidos do conjunto de treinamento referentes àquela dobra. Por exemplo, Para a técnica Min-Max, para cada dobra, os valores mínimo e máximo são registrados. são estimadas usando o conjunto de treinamento e posteriormente utilizadas para transformar o conjunto de teste.

4.3. Definições de métricas de desempenho

A precisão da classificação é uma das medidas mais óbvias de classificação. desempenho. É calculado pelo número de exemplos classificados corretamente. em relação ao número total de instâncias. No entanto, essa métrica não é uma boa escolha. Para dados altamente desbalanceados, é fácil obter uma precisão excessivamente otimista. simplesmente classificando todas as instâncias do conjunto de teste como pertencentes à classe majoritária. Portanto, uma escolha diferente de métrica é fundamental para um desempenho significativo. avaliação ao lidar com conjuntos de dados que apresentam diferentes graus de desequilíbrio de classes. Nesse sentido, optamos por avaliar os modelos utilizando duas métricas que

considere a natureza desequilibrada dos conjuntos de dados [36]: F1 e G-Mean. Ambas as métricas podem ser definidas com base nos elementos de uma matriz de confusão, como na Figura 2.

		Actual Class	
		1	0
Predicted Class	1	TP	FP
	0	FN	TN

Figura 2: Matriz de confusão para um problema de duas classes.

Nessa matriz, TP (Verdadeiros Positivos) e TN (Verdadeiros Negativos) representam o número de instâncias que foram corretamente classificadas como positivas e negativas, respectivamente. Em contrapartida, FP (Falsos Positivos) e FN (Falsos Negativos) representam o número de instâncias classificadas incorretamente como positivas e negativas, respectivamente. Nas subseções seguintes, apresentamos uma definição para as métricas F1 e G-Mean.

4.3.1. Definição de F1

O F1, ou pontuação F, é uma média harmônica entre precisão e recall (ou sensibilidade), que por sua vez são definidos como nas Equações 10 e 11.

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (10)$$

$$\text{Recordar} = \frac{TP}{TP + FN} \quad (11)$$

Então, F1 pode ser definido como na Equação 12.

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recordação}}{\text{Precisão} + \text{Recuperação}} = \frac{TP}{TP + \frac{1}{2}(FP + FN)} \quad (12)$$

F1 pode ser visto como um caso particular da métrica F_{β} (Eq.13), com $\beta = 1$.

$$F_{\beta} = \frac{(1 + \beta^2) \cdot TP}{(1 + \beta^2) \cdot TP + \beta^2 \cdot (FP + FN)} \quad (13)$$

4.3.2. Definição de Média G

A média geométrica (G-Mean) é calculada como a raiz quadrada do produto da sensibilidade e da especificidade, conforme a Equação 16. Onde a sensibilidade, ou recall, pode ser vista como a taxa de verdadeiros positivos, enquanto a especificidade pode ser vista como a taxa de verdadeiros negativos.

$$\text{Sensibilidade} = \text{TPR} = \frac{TP}{TP + FN} \quad (14)$$

$$\text{Especificidade} = \text{TNR} = \frac{\text{TN}}{\text{FP} + \text{TN}} \quad (15)$$

$$\text{Média G} = \bar{y} \cdot \text{TPR} \cdot \text{TNR} = \frac{\bar{y} \cdot \text{TP} \times \text{TN}}{(\text{TP} + \text{FN})(\text{TN} + \text{FP})} \quad (16)$$

4.4. Software

Este experimento foi executado usando a linguagem de programação Python, versão 3.8.3, usando, principalmente, as seguintes bibliotecas: Scikit-Learn[15] versão 0.23.1, sklearn lvq versão 1.1.0, DESlib[26] versão 0.3.5 e SciPy[38] versão 1.5.0.

5. Resultados e Discussão

Esta seção apresenta gráficos e tabelas que resumem nossos resultados experimentais, visando responder às questões de pesquisa definidas na Seção 1 e também fornecer análises adicionais.

Na Seção 5.1, para responder à RQ1, comparamos os desempenhos obtidos pelos modelos considerando as diferentes técnicas de escalonamento e respondemos à RQ2 resumindo nossas descobertas com relação a quais modelos são mais (ou menos) sensíveis à escolha da técnica de escalonamento.

Com relação à RQ3, na Seção 5.2, buscamos uma relação entre o comportamento de um modelo monolítico e um conjunto homogêneo construído com ele, considerando a classificação das técnicas de escalonamento para esse modelo específico. Finalmente, na Seção 5.3, apresentamos nossas descobertas sobre como a sensibilidade à escolha da técnica de escalonamento se relaciona com o desempenho do modelo e discutimos como essa análise pode ser útil para a seleção de modelos em diferentes cenários de implantação.

5.1. Desempenho dos modelos

Para responder à questão de pesquisa RQ1 – A escolha da técnica de escalonamento influencia o desempenho da classificação? – para cada conjunto de dados, comparamos o desempenho de classificação de cada modelo quando treinados com as cinco cópias escalonadas do conjunto de dados e com a linha de base, que é o conjunto de dados original, não escalonado. Em seguida, aplicamos um teste de hipótese de Friedman para avaliar a significância estatística das diferenças apresentadas.

A Tabela 3 mostra, para cada um dos 20 modelos de classificação, os valores obtidos para F1 e G-Mean para cada técnica de escalonamento após o cálculo da média em todos os conjuntos de dados. Nessas tabelas, abreviamos os nomes das técnicas de escalonamento como NS - Sem escalonamento (linha de base), SS - Escalonador Padrão, MM - Escalonador Min-Max, MA - Escalonador Máximo Absoluto, RS - Escalonador Robusto e QT - Transformador de Quantis. Os resultados completos dos experimentos podem ser encontrados em arquivos CSV no repositório do GitHub mencionado acima.

É interessante notar que a Tabela 3 mostra que dados não escalonados nem sempre representam o método de pior desempenho. Essa constatação reforça a necessidade de selecionar a técnica de escalonamento adequada e criteriosa para um par específico de conjunto de dados e modelo, visto que uma técnica escolhida de forma descuidada pode ser pior do que não escalonar os dados.

Tabela 3: Desempenho médio dos modelos de classificação. A tabela mostra, para cada modelo, o Média obtida com o par de métrica e técnica de escala. Cada valor é uma média calculada em 82 conjuntos de dados.

Modelo	F1												Média G
	NS	SS	MM	MA	RS	QT	NS	SS	MM	MA	RS	QT	
Linha SVM	0,44	0,51	0,38	0,36	0,49	0,52	0,48	0,56	0,41	0,38	0,54	0,57	
SVM RBF	0,35	0,52	0,48	0,45	0,40	0,45	0,38	0,56	0,51	0,48	0,44	0,49	
KNN	0,51	0,55	0,54	0,53	0,54	0,56	0,56	0,60	0,58	0,57	0,59	0,60	
GNB	0,42	0,40	0,41	0,41	0,42	0,42	0,61	0,59	0,60	0,60	0,62	0,57	
GLVQ		0,10	0,11	0,08	0,09	0,17	0,09	0,11	0,11	0,08	0,09	0,19	0,10
LDA		0,54	0,54	0,54	0,54	0,54	0,52	0,61	0,61	0,61	0,61	0,61	0,59
QDA		0,36	0,37	0,33	0,37	0,38	0,36	0,47	0,48	0,45	0,48	0,49	0,43
GP		0,52	0,36	0,57	0,56	0,44	0,32	0,56	0,38	0,62	0,61	0,48	0,35
DT		0,56	0,56	0,56	0,56	0,57	0,57	0,68	0,68	0,68	0,68	0,69	0,68
Percepção	0,37	0,52	0,47	0,44	0,48	0,47	0,44	0,63	0,55	0,52	0,60	0,58	
MLP	0,08	0,19	0,05	0,05	0,18	0,21	0,09	0,21	0,05	0,05	0,20	0,23	
RF	0,56	0,56	0,55	0,55	0,56	0,55	0,60	0,60	0,60	0,60	0,60	0,60	
XGBoost	0,59	0,58	0,59	0,59	0,59	0,58	0,65	0,65	0,65	0,65	0,65	0,65	0,64
AdaBoost	0,57	0,57	0,57	0,57	0,57	0,57	0,65	0,65	0,65	0,64	0,64	0,64	0,65
Ensacamento	0,39	0,56	0,50	0,48	0,52	0,53	0,44	0,62	0,55	0,52	0,59	0,59	
OLA	0,53	0,60	0,60	0,58	0,58	0,60	0,60	0,70	0,67	0,65	0,68	0,70	
LCA	0,40	0,49	0,46	0,42	0,47	0,48	0,45	0,56	0,53	0,48	0,54	0,55	
MCB	0,53	0,59	0,59	0,58	0,59	0,59	0,60	0,69	0,67	0,65	0,68	0,69	
KNORAE	0,58	0,61	0,61	0,60	0,61	0,62	0,67	0,70	0,70	0,69	0,70	0,71	
KNORAU	0,48	0,57	0,53	0,50	0,55	0,55	0,53	0,63	0,58	0,55	0,61	0,61	

A Tabela 3 também mostra a variação de desempenho quando consideramos diferentes As técnicas de escalonamento parecem ser relevantes para a maioria (14 de 20 modelos), exceto para três modelos monolíticos: LDA, QDA e DT, para os três modelos de conjunto. Baseado em DTs: XGBoost, RF e AdaBoost. Realizamos testes de Friedman para estimar a significância estatística das diferenças observadas no desempenho ao usar diferentes escalas. técnicas. O teste foi realizado considerando essas hipóteses e um nível de significância de 0,05. Nível de significância:

H0 - Não há diferença significativa entre as médias obtidas. para modelos construídos com conjuntos de dados processados com diferentes técnicas de escalonamento.

H1 - Existe uma diferença significativa entre as médias obtidas. para modelos construídos com conjuntos de dados processados com diferentes técnicas de escalonamento.

Para cada um desses testes, cada amostra comparada é composta pelos 82 Medições de desempenho para um determinado par de modelos e técnica de escalonamento, cujas médias foram apresentadas anteriormente na Tabela 3. Para possibilitar uma discussão sobre o papel do balanceamento de turmas nas diferenças de desempenho observadas, Também realizamos outros três conjuntos de testes de Friedman considerando conjuntos de dados em Diferentes estratos de IR: conjuntos de dados com baixo IR (IR < 3,0), ou seja, conjuntos de dados virtualmente balanceados. IR médio (3 < IR <= 9) e IR alto (IR > 9). Resultados para todos os quatro conjuntos de Os resultados dos testes são apresentados na Tabela 4.

A partir desta tabela, notamos que os testes para conjuntos de dados balanceados (ou seja, com baixa taxa de incidência) e os conjuntos de dados IR médios mostram muito menos rejeições da hipótese nula (15 e

Tabela 4: Resultados dos testes de hipótese de Friedman; cada conjunto de testes considera um estrato de Conjuntos de dados com diferentes níveis de IR: baixo, médio, alto e, em seguida, todos os conjuntos de dados. Marcas de seleção. Indica os valores p que rejeitam a hipótese nula.

Modelo	Métrica	Baixa IR Média	IR Alta IR Todos os conjuntos de dados	Valor-p	Valor-p F1
		0,0040 0,0121 Média-G 0,0017		valor-p	valor p
SVM lin_	0,0004 F1 0,0082 0,7154 Média-G 0,0108			0,0000	0,0000
	0,5642 F1 0,2732 0,8664 Média-G 0,2500			0,0000	0,0000
SVM RBF	0,9975 F1 0,8886 0,1820 Média-G 0,8886			0,0001	0,0000
	0,0823 F1 0,3480 0,7904 Média-G 0,7364			0,0001	0,0000
KNN	0,7423 F1 0,5364 0,5364 Média-G 0,5364			0,0722	0,0182
	0,0005 F1 0,0016 0,3045 Média-G 0,0078			0,2172	0,0732
GNB	0,7324 F1 0,0263 0,2627 Média-G 0,0405			0,0001	0,0000
	0,1699 F1 0,5288 0,0869 Média-G 0,4136			0,0000	0,0000
GLVQ	0,1139 F1 0,0024 0,0038 Média-G 0,0000			0,0000	0,0027
	0,0217 F1 0,0000 0,0001 Média-G 0,0000			0,0000	0,0039
LDA	0,0000 F1 0,2858 0,5907 Média-G 0,2229			0,2239	0,0132
	0,5907 F1 0,0933 0,8063 Média-G 0,0933			0,2239	0,0002
QDA	0,8063 F1 0,2448 0,5662 Média-G 0,2448			0,0512	0,0052
	0,5662 F1 0,0041 0,0078 Média-G 0,0014			0,0133	0,0006
	0,0102 F1 0,5834 0,6362 Média-G 0,6915			0,0000	0,0000
	0,9364 F1 0,0633 0,0309 Média-G 0,0226			0,0000	0,0000
DT	0,0364 F1 0,1317 0,8412 Média-G 0,1510			0,0164	0,1037
	0,4385 F1 0,5368 0,3985 Média-G 0,6592			0,0361	0,1198
Percepção	0,2445 F1 0,2378 0,5939 Média-G 0,1257			0,0000	0,0000
	0,3655 F1 Média-G Total			0,0000	0,0000
MLP				0,0000	0,0000
				0,0000	0,0000
RF				0,4050	0,5169
				0,7535	0,4980
XGBoost				0,1639	0,9574
				0,1639	0,9574
AdaBoost				0,0137	0,0705
				0,0137	0,0705
ensacamento				0,0000	0,0000
				0,0000	0,0000
OLA				0,0160	0,0322
				0,0002	0,0011
				0,0000	0,0000
				0,0000	0,0000
MCB				0,3877	0,0744
				0,1434	0,0256
KNORAE				0,6109	0,2935
				0,9499	0,7844
KNORAU				0,0000	0,0000
				0,0000	0,0000
H0				13	14
Rejeições				14	14
		7 8 15	5 6 11	27	28

11 rejeições em 40, respectivamente) do que aquelas realizadas considerando todas as conjuntos de dados (28 rejeições em 40) ou mesmo apenas os conjuntos de dados de alta IR (27 rejeições) (de 40). Essa observação indica que, embora a sensibilidade da escala

O problema persiste mesmo em conjuntos de dados mais equilibrados; conjuntos de dados altamente desequilibrados são mais propensos a variações significativas de desempenho devido à escolha de diferentes técnicas de escalonamento. Além disso, mesmo para conjuntos de dados balanceados, o valor p muito baixo

Os valores observados para SVMs, QDA, Percep, MLP e Bagging indicam que essas diferenças de desempenho não devem ser negligenciadas.

Agora, direcionamos nossa atenção para as duas últimas colunas da Tabela 4, que correspondem aos resultados dos testes considerando todos os 82 conjuntos de dados. Ao levarmos em conta os modelos monolíticos (de SVM lin a MLP), os resultados indicam que a hipótese nula pode ser rejeitada na maioria dos casos, exceto para o modelo de Árvore de Decisão (DT) e parcialmente (em uma das duas métricas) para o modelo KNN. Embora, no caso do KNN, o valor p de 0,07 tenha ficado próximo do limite de 0,05. Isso significa que, para quase todos os modelos monolíticos estudados, há uma diferença significativa no desempenho quando diferentes técnicas de escalonamento são aplicadas a conjuntos de dados desbalanceados.

A insensibilidade à escala observada no modelo DT já era esperada, visto que este é um modelo baseado em regras, e ele atribui limiares de decisão para cada atributo independentemente da escala dos outros atributos.

Embora esperássemos que o modelo KNN apresentasse diferenças de desempenho mais significativas entre as diferentes técnicas de escalonamento, ele não foi tão afetado quanto outros classificadores, como SVM lin, SVM RBF MLP, Perceptron e GP. Deve-se lembrar que esse modelo só é sensível à escala quando a diferença entre as características altera significativamente o conjunto de vizinhos de uma instância.

Assim, afetando a classificação final. Isso pode não ser necessariamente o caso com a maioria dos conjuntos de dados estudados.

Para os modelos de conjunto, os resultados mostram que os conjuntos construídos com Árvores de Decisão como modelos base (RF, XGBoost e AdaBoost) também são insensíveis à escolha da técnica de escalonamento. Por outro lado, os demais conjuntos, construídos com Perceptrons como modelos base, são sensíveis à escala dos dados, com o modelo KNORAE sendo uma exceção notável. Isso indica que parece haver uma relação entre a sensibilidade à escala observada em um modelo monolítico e a de um conjunto construído com base nesse modelo. Este tópico é explorado mais detalhadamente na Seção 5.2, onde respondemos à RQ3.

Quanto à estabilidade observada nos resultados do modelo KNORAE, uma possível explicação é que o algoritmo funciona selecionando todos os classificadores base com desempenho perfeito na região de competência (RoC) da instância de consulta (seus k vizinhos mais próximos). Enquanto nenhum classificador atingir desempenho perfeito na RoC, k continua sendo decrementado em 1, reduzindo a região de interesse. Dessa forma, quando o(s) vizinho(s) mais distante(s) é(são) eliminado(s), o algoritmo remove amostras com valores extremos para algumas características. Assim, ele alcança uma RoC onde as amostras apresentam escalas mais bem comportadas entre suas características, sobre as quais uma escolha diferente de técnica de escalonamento tem pouco efeito.

Para melhor visualizar a diferença de desempenho que a escolha da técnica de escalonamento pode promover, a Figura 3 apresenta os gráficos de barras que representam a variação de desempenho para cada modelo. A média de todos os conjuntos de dados é considerada aqui. Esses gráficos, como esperado, corroboram os resultados e conclusões obtidos no teste de hipóteses, pois podemos observar maiores amplitudes para os modelos monolíticos SVM, GP, Percep e MLP, e amplitudes muito baixas para o modelo DT e os ensembles construídos com ele como modelo base.

Além disso, observe que, para os modelos monolíticos, a diferença média de desempenho (intervalo médio) é próxima ou superior a 0,15 para cinco modelos.

(SVM lin, SVM RBF, GP, Percep e MLP), e isso pode representar, em alguns contextos, a diferença entre um modelo útil e um inútil. Para os modelos de conjunto, as diferenças são menos impressionantes, mas não desprezíveis.




Figura 3: Intervalos médios (diferenças entre a melhor e a pior técnica de escalonamento) para o monolítico e modelos de conjunto.

Com base em todas as evidências acima, podemos responder à questão de pesquisa RQ1: Sim, a escolha da técnica de escalonamento é importante para o desempenho da classificação. Podemos verificar isso tanto para modelos monolíticos quanto para modelos de conjunto. Os testes de hipóteses mostram que as diferenças de desempenho são significativas para a maioria dos modelos. A variação na extensão em que o escalonamento afeta o desempenho de diferentes modelos nos leva à nossa próxima questão de pesquisa.

Com os mesmos recursos que utilizamos para responder à RQ1, também podemos responder à questão de pesquisa RQ2 – Quais modelos apresentam maiores variações de desempenho quando os conjuntos de dados são escalados com diferentes técnicas? – começamos analisando a Figura 3, que apresenta as faixas médias (considerando todos os 82 conjuntos de dados) no desempenho do modelo (diferença entre a melhor e a pior técnica de escala). Como discutido anteriormente, parece haver uma grande variabilidade para alguns modelos, tanto em grupos monolíticos quanto em grupos de ensemble, e quase nenhuma variação ao considerarmos alguns modelos selecionados.

É importante ressaltar que a Figura 3 apresenta as médias de todos os 82 conjuntos de dados. Em seguida, para os modelos mais sensíveis, o ganho de desempenho ao escolher a técnica de escalonamento correta pode ser ainda maior para alguns conjuntos de dados. Se tomarmos como exemplo o modelo SVM lin, observando os resultados brutos (disponíveis nos materiais suplementares), podemos ver que sua diferença máxima entre a melhor e a pior técnica de escalonamento ocorreu para o conjunto de dados "segment-0", com uma amplitude de 0,991 para a métrica F1. Esse resultado para o conjunto de dados "segment-0" não é exatamente um valor atípico, visto que, para o modelo SVM lin, a amplitude alcançada em 26 (32%) dos 82 conjuntos de dados foi superior a 0,5 e, em 6 (7%) deles, a amplitude foi superior a 0,8. Essas são diferenças extremas entre os melhores e os piores desempenhos.

O mesmo modelo foi causado apenas pela troca das técnicas de escala. Isso além disso enfatiza a necessidade de uma escolha cuidadosa da técnica de escalonamento a ser aplicada em uma tarefa de classificação.

Podemos observar na Figura 3 que alguns modelos, como SVM lin, SVM RBF, GLVQ, GP, Percep, MLP, Bagging, OLA, LCA e KNORAU apresentam maiores Os intervalos médios, enquanto modelos como DT e os conjuntos baseados em DT (RF, XG-Boost e AdaBoost) são quase insensíveis à escolha da técnica de escalonamento. Isso é confirmado pelos resultados dos testes de Friedman na Tabela 4, o que nos leva a... para algumas generalizações possíveis: Considerando os modelos monolíticos e suas Das categorias na Tabela 1, os modelos baseados em instâncias (KNN é uma exceção) e as Redes Neurais (MLP e Percep) parecem ser mais sensíveis à forma como os dados são apresentados. escalados. Em contraste, os modelos baseados em regras e em análise discriminante são menos sensíveis. Quando consideramos os modelos de conjunto, aqueles construídos usando árvores de decisão como seus modelos básicos (XGBoost, RF e AdaBoost) são igualmente insensíveis ao A técnica de escalonamento escolhida, enquanto aquelas baseadas em Perceptrons (todas as outras) são mais sensível.

Como análise adicional, na Tabela 5 apresentamos o número de vitórias de cada um. técnicas de escalonamento (quantas vezes cada uma foi melhor que as outras) para cada estrato IR. Isso nos permite concluir que, considerando todos os estratos IR A técnica de Transformação Quantil (QT) é a mais bem-sucedida. Em baixas taxas de incidência (IR). No estrato, a melhor técnica é o Standard Scaler (SS), enquanto no estrato médio e Em estratos socioeconômicos elevados, o Transformador Quantílico volta a ser a técnica de melhor desempenho. Isso indica que a IR pode ser uma variável importante para determinar qual A técnica de escalonamento é a mais adequada para um determinado conjunto de dados.

Tabela 5: Número de vitórias por técnica de escalonamento considerando todos os 82 modelos. Cada estrato IR (baixo, médio e alto) consideram apenas os conjuntos de dados dentro desse estrato. O melhor resultado para Cada linha está destacada em negrito.

Estrato IR	NS	SS	MM	MA	RS	QT
Todos	125.533	168.100	105.883	109.467	172.233	220.783
Infravermelho baixo	12,817	32,567	15,733		10,983	23,450
Infravermelho médio	15,900	19,650	11,983		19.983	22.983
Infravermelho alto	96,817	115,883	78,167	78,500		125.800

5.2. As técnicas de escalonamento têm classificação semelhante para um conjunto e seu modelo base?

Até este ponto, podemos observar na Figura 3 que existe uma relação aparente entre a variabilidade de escala observada nos conjuntos e a de seus respectivos grupos.

modelos base. Essa observação exige uma investigação mais aprofundada, que pretendemos realizar. prosseguiremos enquanto respondemos à questão de pesquisa RQ3 - Realizar conjuntos homogêneos tendem a seguir o padrão de variação de desempenho apresentado pelo seu modelo base.

Ao lidar com diferentes técnicas de escalonamento?

Por "padrão de variação de desempenho", entendemos a ordem em que o escalonamento As técnicas são classificadas ao se considerar um modelo e conjunto de dados específicos. Em seguida, nós... O objetivo é responder se, em média, a melhor técnica de escalonamento de classificação é a mesma.

entre um modelo monolítico específico e seu conjunto correspondente, e também se as técnicas de segunda e terceira classificação, e assim por diante, forem coincidentes.

Para melhor comparar essas classificações para um modelo monolítico e um conjunto construído com ele, devemos selecionar um modelo monolítico e todos os seus conjuntos correspondentes. Devido à forma como projetamos os conjuntos em nosso estudo, temos dois modelos monolíticos possíveis para este estudo: DT ou Percep, pois os conjuntos que construímos têm DT ou Percep como modelos base. Como já verificamos que o modelo DT e seus conjuntos correspondentes são praticamente insensíveis à escala, optamos por comparar o modelo monolítico Percep e os conjuntos construídos com ele como modelo base: Bagging, OLA, LCA, MCB, KNORAE e KNORAU.

Embora estejamos limitando esta análise a perceptrons e ensembles baseados em perceptrons, este é um modelo especialmente útil para a construção de ensembles devido à sua simplicidade, baixo custo computacional e sensibilidade à amostragem de dados, o que ajuda a promover a tão desejada diversidade do ensemble [22]. Além disso, foi demonstrado na literatura de DES que o uso de modelos fracos como classificador base, como árvores de decisão e perceptrons, permite melhores resultados, superando modelos mais fortes como Random Forest, SVM ou MLP [39, 40, 41, 42, 43].

A Figura 4 mostra, para o Percep e os seis ensembles baseados nele, o padrão de variação de desempenho juntamente com as diferentes técnicas de escalonamento para as métricas F1 e G-Mean. Cada barra representa o resultado médio em todos os 82 conjuntos de dados para a técnica de escalonamento e métrica correspondentes.

Observamos, a partir desses gráficos de barras, que, para ambas as métricas, as melhores e piores técnicas de escalonamento coincidem para todos os modelos: os melhores desempenhos foram obtidos com o Standard Scaler e os piores resultados com dados não escalonados (NS). Isso reforça nossa crença na relação entre o comportamento do modelo Percep e seus ensembles derivados. No entanto, podemos observar contraexemplos ao analisarmos a segunda barra em cada modelo: enquanto para o Percep ela corresponde ao Robust Scaler, para todos os outros modelos corresponde ao Quantile Transformer, embora as diferenças não pareçam ser significativas. Essas observações indicam que uma análise mais aprofundada é necessária para responder a essa questão.

Em vez de analisarmos apenas a classificação das médias na Figura 4, calculamos a classificação média (considerando os 82 conjuntos de dados) de cada técnica de escalonamento para o modelo Percep em comparação com os seis modelos de conjunto correspondentes e representamos os resultados como diagramas de diferença crítica (DC) nas Figuras 5 e 6 para F1 e G-Mean, respectivamente. Esses diagramas de DC foram construídos usando um teste post hoc de Nemenyi.

Nas Figuras 5 e 6, observamos que os ensembles mais sensíveis à escala (ou seja, aqueles mais propensos a mudanças devido à escolha da técnica de escalonamento) tendem a seguir a tendência estabelecida pelo modelo Percep no qual se baseiam. Por exemplo, tanto para F1 quanto para G-Mean, as duas melhores e as duas piores técnicas de escalonamento coincidem quando consideramos o Percep e os modelos de ensemble mais sensíveis (Bagging, LCA e KNORAU): SS e RS aparecem em primeiro e segundo lugares, enquanto MA e NS aparecem em quinto e sexto lugares. No entanto, isso não ocorre para modelos menos sensíveis à escala (especialmente KNORAE), principalmente porque, para esses modelos, as diferenças entre as classificações das distintas técnicas de escalonamento são significativas.




Figura 4: Desempenho médio das seis técnicas de escalonamento para o modelo Perceptron (acima) e seus respectivos conjuntos.

As técnicas de escalonamento são menos significativas, como pode ser visto nas Figuras 5 e 6.

Esses resultados podem ser vistos como uma indicação de que, quando a escala é importante para o conjunto de modelos, os modelos monolíticos podem ditar o comportamento da variabilidade da escala dos dados nos conjuntos construídos com eles como modelo base. Portanto, trata-se de uma descoberta importante, visto que, para escolher a técnica de escalonamento ideal para um conjunto de modelos, os testes podem ser realizados com apenas uma instância do modelo base. Isso acarreta um custo computacional significativamente menor do que executar os mesmos testes com todo o conjunto.

Outra conclusão valiosa das Figuras 5 e 6 é que, para todos os modelos de conjunto, o desempenho com dados não escalonados (NS) é estatisticamente semelhante a pelo menos uma das técnicas de escalonamento adjacentes na classificação, mesmo para os conjuntos mais propensos à variação devido à escala, como o modelo Bagging. Portanto, escolher a técnica de escalonamento errada pode ser tão ruim quanto não escalonar os dados.




Figura 5: Diagramas CD das classificações médias (considerando a métrica F1) das seis técnicas de escalonamento para o modelo Perceptron (acima) e seus respectivos conjuntos.

todos.

5.3. Sensibilidade à escala versus desempenho do

modelo. Se observarmos a Figura 3 e a Tabela 3, podemos ver que existem modelos que apresentam desempenhos superiores, como o KNORAE (próximo a 0,6 para F1 e 0,7 para G-Mean), e outros modelos que são muito sensíveis à escolha da técnica de escala, como o GP, que apresenta uma faixa média próxima a 0,26 para ambas as métricas. No entanto, é difícil perceber, a partir desses recursos, como a sensibilidade à escala e o desempenho do modelo se relacionam.

Para melhor visualizar essa relação, a Figura 7 apresenta dois diagramas de dispersão, um para cada métrica, onde comparamos a média.




Figura 6: Diagramas CD, utilizando o teste de Nemeyi, das classificações médias (considerando a métrica **G-Mean**) das seis técnicas de escalonamento para o modelo Perceptron (acima) e seus respectivos conjuntos.

O gráfico mostra a amplitude em relação à classificação média de cada modelo. Para a amplitude média, consideramos as amplitudes (diferenças entre os desempenhos das melhores e piores técnicas de escalonamento) obtidas por um modelo em cada um dos 82 conjuntos de dados e, em seguida, calculamos a média. Para a classificação média, calculamos a posição de um modelo em comparação com os demais em cada conjunto de dados e, em seguida, calculamos a média de todas as 82 classificações desse modelo. Como cada modelo é aplicado a seis versões do mesmo conjunto de dados (uma para cada técnica de escalonamento), para a classificação, levamos em consideração seu melhor desempenho entre as seis versões. Nesses gráficos, a classificação média é melhor quanto menor for. Esses gráficos de dispersão mostram uma maneira de analisar os resultados.

as sensibilidades de escala dos modelos e seus desempenhos, em termos de sua classificação média nos 82 conjuntos de dados.

Essa é uma análise importante quando se precisa selecionar um modelo ou um grupo de modelos para implantação em aplicações do mundo real com diferentes requisitos. Por exemplo, o escalonamento do conjunto de dados geralmente não é uma opção para uma aplicação em tempo real ou online, na qual o treinamento do modelo é executado dinamicamente. Portanto, seria necessário escolher um modelo que tenha bom desempenho independentemente da escala dos dados, como DT ou AdaBoost. No outro extremo, para uma aplicação estática e mais convencional, quando o treinamento é feito antes da implantação, faz mais sentido priorizar o desempenho em detrimento da estabilidade de escala, o que levaria à escolha de um modelo como KNORAE, MCB ou OLA.

Outra observação interessante da Figura 7 é que o modelo DT e os ensembles baseados em DT (AdaBoost, RF e XGBoost) aparecem em um cluster posicionado na porção central esquerda do espaço. Isso significa que eles são praticamente insensíveis à escala – concordando com discussões anteriores – ao mesmo tempo que apresentam um desempenho razoável. Além disso, o fato de estarem juntos em um cluster significa que há pouca diferença na escolha de um em relação aos outros. Isso é um tanto surpreendente, visto que esperávamos que esses ensembles, mesmo sendo estáticos, apresentassem uma classificação consistentemente melhor em todos os conjuntos de dados quando comparados ao seu modelo base.

Por outro lado, o modelo perceptron (Percep) e os ensembles construídos com ele como modelo base (OLA, LCA, MCB, KNORAE e KNORAU) apresentam uma distribuição mais dispersa no espaço, sendo o KNORAE, simultaneamente, o de melhor desempenho e o menos sensível à escala quando comparado aos demais ensembles baseados em perceptron. Destaca-se também que, embora Percep e DT apresentem classificações médias muito semelhantes, seus ensembles se posicionam de maneira bastante distinta no espaço, o que pode ser consequência de suas naturezas diferentes, especialmente em relação ao método de seleção do classificador: estático versus dinâmico. Isso poderia ser investigado mais a fundo construindo ensembles dinâmicos de DTs, bem como ensembles estáticos de perceptrons. Esperamos que um KNORAE baseado em DT se posicione mais próximo da origem neste grafo.

6. Obras Relacionadas

Esta seção apresenta, em ordem cronológica, uma revisão dos poucos artigos publicados até o momento, segundo nosso conhecimento, que apresentam uma análise comparativa dos efeitos de diferentes técnicas de escalonamento no desempenho de classificação de algoritmos de aprendizado de máquina. Na Tabela 6, resumimos as técnicas de escalonamento, o número de conjuntos de dados e os modelos de classificação que cada um desses artigos empregou em seus experimentos. A última linha apresenta as mesmas informações referentes ao experimento conduzido neste artigo.

Podemos observar, pela Tabela 6, que o trabalho anterior carecia de uma análise suficientemente diversificada em relação às três perspectivas: número de técnicas, conjuntos de dados e algoritmos de classificação.

Jain et al. [4] e Dzierżak et al. [5], por exemplo, consideraram apenas duas técnicas de escala em seus experimentos, que foram a normalização Min-max e a normalização Z-score.





Figura 7: Gráficos de dispersão que relacionam a sensibilidade à escala do modelo (intervalo médio) com seu desempenho (classificação média) considerando as métricas (a) F1 e (b) G-Mean.

Tabela 6: Amplitude dos trabalhos relacionados e deste artigo.

Papel	técnicas de escalonamento	Conjuntos de dados	Algoritmos de classificação	
			Monolítico	Conjunto
Jain et al. [4] 2018	Duas técnicas: Min-max e escore Z.	48	1 algoritmo: ELM com Kernel Gaussiano. 4	
Dzierżak et al. [5] 2019	Duas técnicas: Min-max e escore Z.	1	algoritmos: Naive Bayes, SVM, MLP, Classificação via regressão.	1 algoritmo: Florestas Aleatórias (RF)
Raju et al. [6] 2020	7 técnicas: Min-max, Z-score, Escala, Escala Robusta, Transformação de Quantis, Transformação de Potência, Escala de Máximo Absoluto. 14 técnicas: Z-score, Min-max (2 variantes), Centralização da Média, Escala de Pareto, Escala de Estabilidade de Variáveis, Transformação de Potência, Escala de Máximo Absoluto, Escala Decimal, Normalização da Mediana e do Desvio Absoluto da Mediana, Normalização da Tanh (2 variantes), Sigmoid Logística, Tangente Hiperbólica.	1	3 algoritmos: SVM (2 variantes), KNN.	
Singh et al. [1] 2020	16 técnicas: Z-score, Padronização Positiva, Unitização, Min-max, Normalização (3 variantes), Normalização Positiva (2 variantes), Transformação de Quociente (7 variantes).	21	1 algoritmo: KNN	
Mishkov et al. [3] 2022	5 técnicas: Min-max, Z-score, Escala de Máximo Absoluto, Escala Robusta, Transformação de Quantis.	4	1 algoritmo: MLP	
Este artigo		82	11 algoritmos: SVM (2 variantes), KNN, GLVQ, GNB, GP, LDA, QDA, DT, Percep, MLP.	9 algoritmos: XGBoost, RF, AdaBoost, Bagging, OLA, LCA, MCB, KNORAE, KNORAU.

No caso de Jain et al. [4], os autores focam seu estudo na seleção dinâmica de uma dessas duas técnicas com base em medidas de complexidade de dados. Embora este artigo relate os desempenhos obtidos pelas técnicas, uma comparação é realizada apenas minimamente, visto que não é seu foco principal. Dzierżak et al. [5] avaliaram a influência dessas duas técnicas de escalonamento no desempenho de um modelo para detectar osteoporose e osteopenia a partir de um único conjunto de dados composto por 290 características representando imagens de tomografia computadorizada (TC) de seções da coluna vertebral de pacientes. Seus resultados indicaram a superioridade do método Z-score na melhoria do desempenho da classificação. No entanto, eles não empregaram um teste de hipótese para avaliar a significância estatística da melhoria em relação ao método Min-max.

Embora Raju et al. [6], Singh et al. [1] e Mishkov et al. [3] tenham conseguido comparar conjuntos significativamente maiores e mais diversos de técnicas de escalonamento, todos eles falharam em incluir um conjunto diversificado de algoritmos de classificação. Além disso, no que diz respeito à generalidade de suas descobertas, apenas em Singh et al. [1] um número relevante de conjuntos de dados foi considerado.

Raju et al. [6] aplicaram sete técnicas de escalonamento distintas em um conjunto de dados de diabetes do Kaggle e, em seguida, compararam o desempenho de três modelos de classificação: KNN e duas variantes de SVM. Os autores compararam os resultados do modelo com cada técnica de escalonamento ao desempenho obtido nos dados originais (não escalonados). Essas comparações mostraram que o escalonamento permitiu um aumento de desempenho em todos os aspectos.

caso, variando de 5% a 10%. Corroborando nossas descobertas sobre a insensibilidade do modelo KNN à escolha da técnica de escalonamento, em seus resultados o KNN foi o menos sensível quando comparado às duas variantes do SVM. Além de comparar o desempenho obtido com cada técnica de escalonamento versus o dos dados não escalonados, também foi realizada uma comparação das técnicas de escalonamento entre si. No entanto, o artigo careceu de uma análise mais aprofundada dos resultados, juntamente com testes de hipóteses.

Singh et al. [1] empregaram 14 técnicas de escalonamento em 21 conjuntos de dados e, em seguida, compararam o desempenho de um classificador k-Nearest Neighbors (KNN) treinado nos conjuntos de dados escalonados e não escalonados. Os resultados dos experimentos, ao usar o conjunto completo de características, sugerem que a maioria dos métodos ajuda a melhorar a precisão; dados não escalonados nem sempre levam à pior precisão, o que corrobora nossas conclusões na Seção 5.1. Testes de hipóteses confirmaram que diferentes técnicas permitem resultados significativamente diferentes, mas apenas duas técnicas (Escalonamento de Pareto e Transformação de Potência) foram significativamente melhores do que os dados não escalonados. No entanto, os autores não realizaram uma análise envolvendo algoritmos de classificação diferentes do KNN.

Finalmente, Mishkov et al. [3] aplicaram 16 técnicas de escalonamento a 4 conjuntos de dados diferentes para comparar a precisão de classificação de um Perceptron Multicamadas (MLP). Seus resultados mostraram que a escolha da técnica de escalonamento influencia a precisão da classificação e sugeriram que essa decisão deve ser tomada caso a caso, ou seja, dependendo do conjunto de dados analisado. Eles também observaram que dados não escalonados nem sempre levam ao pior desempenho, concordando com nossas descobertas na Seção 5.1. Este artigo também não incluiu uma análise envolvendo outros algoritmos de classificação.

Em resumo, dois dos cinco artigos focam suas análises em apenas duas técnicas de escalonamento [4, 5], enquanto aqueles que experimentam um número maior de técnicas restringem seus testes a apenas um [1, 3] ou três algoritmos de classificação [6]. Além disso, somente em [4] e [1], os autores forneceram resultados de um número relevante de conjuntos de dados. Portanto, a literatura carece de trabalhos de pesquisa que considerem várias técnicas de escalonamento, um número razoável de conjuntos de dados e algoritmos de classificação simultaneamente. Adicionalmente, notamos que nenhum desses trabalhos comparou o efeito das técnicas de escalonamento em conjuntos de dados afetados por diferentes taxas de desbalanceamento, nem mediu seu impacto em modelos de ensemble além do tradicional Random Forest, incluído em apenas dois dos cinco artigos.

É importante mencionar também que, embora nos dois artigos mais recentes [1, 3] os autores tenham empregado um conjunto significativamente maior de técnicas de escalonamento do que todos os outros trabalhos (incluindo o nosso), algumas dessas técnicas são muito semelhantes ou até mesmo equivalentes entre si. Conforme relatado em [1], muitas das técnicas frequentemente retornam os mesmos resultados para a maioria dos conjuntos de dados. Além disso, em [3], o conjunto de técnicas é ampliado consideravelmente devido à decisão de adicionar até 7 variantes da mesma técnica. Em nosso artigo, buscamos selecionar um conjunto diversificado, porém conciso, de técnicas que acreditamos ser suficientemente representativo das técnicas de escalonamento disponíveis, conforme detalhamos na Seção 2.

7. Lições aprendidas

- A escolha da técnica de escalonamento é importante para o desempenho da classificação. Exceto para modelos que, por natureza, não são sensíveis à escala, a diferença de desempenho entre a melhor e a pior técnica de escalonamento é relevante e estatisticamente significativa na maioria dos casos.
- Escolher a técnica de escalonamento errada pode ser mais prejudicial ao desempenho da classificação do que não escalonar os dados. Para o modelo SVM linear, por exemplo, a diferença no F1 foi superior a 0,5 para 32% dos conjuntos de dados e superior a 0,8 para 7% deles.
- A diferença de desempenho considerando as distintas técnicas de escalonamento pode ser observada em conjuntos de dados que apresentam todos os níveis de desequilíbrio de classes. No entanto, parece ser mais evidente em conjuntos de dados com maior taxa de incompatibilidade (IR).
- A técnica Standard Scaler foi a mais eficaz em conjuntos de dados com baixa taxa de incidência, mas a técnica Quantile Transformer apresentou melhor desempenho em todos os outros estratos de taxa de incidência. Isso indica que a recuperação de informação pode desempenhar um papel importante na seleção da melhor técnica de escalonamento para um conjunto de dados.
- Modelos como SVMs, GLVQ, Processo Gaussiano, Perceptron, MLP, Bagging, OLA, LCA e KNORA-U são muito sensíveis à escolha da técnica de escalonamento.
- Árvores de Decisão (AD) e conjuntos baseados em AD são praticamente insensíveis à escolha da técnica de escalonamento. Por outro lado, conjuntos construídos com Perceptrons apresentam uma gama maior de sensibilidade à escolha das técnicas de escalonamento e a diferentes desempenhos de F1 e G-Mean.
- Para ensembles mais sensíveis à escolha de técnicas de escalonamento, como Bagging, LCA e KNORAU, as técnicas de escalonamento tendem a apresentar desempenho semelhante aos seus modelos base. Isso indica que, quando a escala é importante para o ensemble, os modelos base podem ditar o comportamento da variabilidade de escala dos dados em seus ensembles. Portanto, testar qual técnica de escalonamento é a melhor para um ensemble pode ser feito executando apenas uma instância de seu modelo base, incorrendo em um custo computacional significativamente menor.
- Para aplicações de classificação em tempo real ou online, nas quais o treinamento do modelo é executado instantaneamente, com os dados sendo transmitidos continuamente para o processo de aprendizagem e, portanto, difíceis de serem escalados de forma eficaz, modelos como Árvore de Decisão (DT) ou AdaBoost são preferíveis, pois apresentam a menor sensibilidade à escala, ao mesmo tempo que alcançam desempenhos razoáveis.
- Para aplicações estáticas, quando se pode priorizar o desempenho em detrimento da estabilidade de escala, KNORAE, MCB ou OLA são as escolhas mais razoáveis, visto que são as que apresentam os melhores desempenhos médios, considerando que os dados estejam adequadamente dimensionados.

8. Conclusão

Este estudo buscou compreender se a escolha da técnica de escalonamento influencia significativamente o desempenho de modelos de classificação e se essa influência varia de acordo com os tipos de modelos utilizados, incluindo modelos monolíticos e de conjunto. Realizamos um amplo experimento com cinco técnicas de escalonamento, 82 conjuntos de dados binários, apresentando uma ampla gama de taxas de desbalanceamento, e 20 modelos de classificação, compreendendo 11 algoritmos monolíticos de cinco subcategorias diferentes e nove algoritmos de conjunto, incluindo modelos estáticos, DCS e DES.

Os resultados indicaram que a escolha da técnica de escalonamento afeta significativamente o desempenho da classificação e que escolher a técnica de escalonamento errada pode ser ainda pior do que não escalonar os dados. A análise da sensibilidade à escala versus o desempenho do modelo revelou a relação entre um conjunto de modelos e seus modelos base quando observamos as variações de desempenho. Também mostrou que não existe uma solução única para todos os casos quando se trata de implantação de modelos, onde as restrições da aplicação, como a viabilidade do escalonamento e outros requisitos, podem determinar o modelo mais apropriado. Isso reforça a importância dessa análise como ferramenta para seleção de modelos.

Em trabalhos futuros, pretendemos investigar mais a fundo essa relação entre a variabilidade de desempenho devido à escolha da técnica de escalonamento de um ensemble e seu modelo base, por exemplo, para melhor compreender como um ensemble, quando comparado ao seu modelo base, consegue reduzir a variação de desempenho considerando diferentes técnicas de escalonamento e como diferentes configurações e tipos de ensembles se apresentam no gráfico da Figura 7. Outra direção possível é entender quais características dos dados são importantes para a seleção de técnicas de escalonamento, o que também pode subsidiar pesquisas em meta-aprendizagem voltadas para a seleção dinâmica de técnicas de escalonamento.

Referências

- [1] D. Singh, B. Singh, Investigando o impacto da normalização de dados no desempenho da classificação, *Applied Soft Computing* 97 (2020) 105524. doi:10.1016/j.asoc.2019.105524.
- [2] J. Alcalá-Fdez, A. Fernández, J. Luengo, J. Derrac, S. García, L. Sánchez, F. Herrera, Ferramenta de software de mineração de dados KEEL: Repositório de conjunto de dados, integração de algoritmos e estrutura de análise experimental, *Journal of Multiple-Valued Logic and Soft Computing* 17 (2-3) (2011) 255–287.
- [3] O. Mishkov, K. Zorin, D. Kovtoniuk, V. Dereko, I. Morgun, Análise comparativa de técnicas de normalização baseadas no uso de critérios de qualidade de classificação, *Lecture Notes on Data Engineering and Communications Technologies* 77 (2022) 602–612. doi:10.1007/978-3-030-82014-5_41.
- [4] S. Jain, S. Shukla, R. Wadhvani, Seleção dinâmica de técnicas de normalização usando medidas de complexidade de dados, *Expert Systems with Applications* 106 (2018) 252–262. doi:10.1016/j.eswa.2018.04.008.

- [5] R. Dzierżak, Comparação da influência da padronização e normalização de dados na eficácia da classificação da textura do tecido esponjoso, *Informatyka, Automatyka, Pomiar w Gospodarce i Ochronie Środowiska* 9 (3) (2019) 66–69. doi:10.35784/iapgos.62.
- [6] VNG Raju, KP Lakshmi, VM Jain, A. Kalidindi, V. Padma, Estudo da influência do processo de normalização/transformação na precisão da classificação supervisionada, em: 2020 Third International Conference on Smart Systems and Inventive Technology (ICSSIT), IEEE, 2020, pp. 729–735. doi:10.1109/ICSSIT48917.2020.9214160.
- [7] RM Cruz, R. Sabourin, GD Cavalcanti, Seleção dinâmica de classificadores: avanços e perspectivas recentes, *Information Fusion* 41 (2018) 195–216. doi:10.1016/j.inffus.2017.09.010.
- [8] L. Eriksson, Introdução à análise de dados multivariados e megavariados usando métodos de injeção (PCA e PLS), Umetrics AB, 1999.
- [9] HC Keun, TM Ebbels, H. Antti, ME Bollard, O. Beckonert, E. Holmes, JC Lindon, JK Nicholson, Análise aprimorada de dados multivariados por escalonamento de estabilidade variável: Aplicação ao perfil metabólico baseado em RMN, *Analytica Chimica Acta* 490 (1-2) (2003) 265–276. doi:10.1016/S0003-2670(03)00094-1.
- [10] Y. Hu, V. Gripon, S. Pateux, Leveraging the Feature Distribution in Transfer-Based Few-Shot Learning, in: I. Farkas, P. Masulli, S. Otte, S. Wermter (Eds.), *Artificial Neural Networks and Machine Learning – ICANN 2021*, Springer International Publishing, Cham, 2021, pp. 487–499.
- [11] 6.3. pré-processamento de dados (outubro de 2021).
URL <https://scikit-learn.org/stable/modules/preprocessing.html#preprocessing-transformer>
- [12] T. Cover, P. Hart, Classificação de padrões de vizinhos mais próximos, *IEEE Transactions on Information Theory* 13 (1) (1967) 21–27. doi:10.1109/TIT.1967.1053964.
- [13] A. Sato, K. Yamada, Quantização vetorial de aprendizagem generalizada, *Anais da 8ª Conferência Internacional sobre Sistemas de Processamento de Informação Neural* (1996) 423–429.
- [14] C. Cortes, V. Vapnik, Redes de vetores de suporte, *Aprendizado de máquina* 20 (3) (1995) 273–297. doi:10.1023/A:1022627411411.
- [15] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Pas-sos, D. Cournapeau, M. Brucher, M. Perrot, E. Duchesnay, Scikit-learn: Aprendizado de máquina em Python, *Journal of Machine Research de Aprendizagem* 12 (2011) 2825–2830.

- [16] I. Rish, Um estudo empírico do classificador Naive Bayes, Workshop IJCAI 2001 sobre métodos empíricos em inteligência artificial 3 (22) (2001) 41–46.
- [17] H. Zhang, A otimalidade do Naive Bayes, em: Anais da Décima Sexta Conferência Internacional da Sociedade de Pesquisa em Inteligência Artificial da Flórida, FLAIRS 2004, Vol. 2, 2004, pp. 562–567.
- [18] M. Seeger, Processos Gaussianos para aprendizado de máquina., International journal of neural systems 14 (2) (2004) 69–106. doi:10.1142/S0129065704001899.
- [19] AKH Tung, Classificação baseada em regras, Springer US, Boston, MA, 2009, pp. 2459–2462. doi:10.1007/978-0-387-39940-9_559.
- [20] L. Breiman, JH Friedman, RA Olshen, CJ Stone, Classificação e Árvores de regressão, Routledge, 2017. doi:10.1201/9781315139470.
- [21] CC Aggarwal, Redes Neurais e Aprendizado Profundo, 1ª Edição, Springer International Publishing, Cham, 2018. doi:10.1007/978-3-319-94463-0.
- [22] LI Kuncheva, Combinando classificadores de padrões: métodos e algoritmos, 2ª edição, John Wiley and Sons, 2014.
- [23] Z.-H. Zhou, Métodos de Conjunto, Fundamentos e Algoritmos, Chapman & Hall/CRC, 2012.
- [24] S. Tulyakov, S. Jaeger, V. Govindaraju, D. Doermann, Review of Classifier Combination Methods, Springer Berlin Heidelberg, Berlin, Heidelberg, 2008, pp. 361–386. doi:10.1007/978-3-540-76280-5_14.
- [25] T. Chen, C. Guestrin, XGBoost: Um sistema de boosting de árvores escalável, em: Anais da Conferência Internacional ACM SIGKDD sobre Descoberta de Conhecimento e Mineração de Dados, nº 8, ACM, Nova York, NY, EUA, 2016, pp. 785–794. arXiv:1603.02754, doi:10.1145/2939672.2939785.
- [26] RMO Cruz, LG Hafemann, R. Sabourin, GDC Cavalcanti, Deslib: Uma biblioteca de seleção de conjunto dinâmico em Python, Journal of Machine Learning Research 21 (8) (2020) 1–5.
- [27] L. Breiman, Bagging predictors, Machine Learning 24 (2) (1996) 123–140. doi:10.1007/BF00058655.
- [28] L. Breiman, Florestas aleatórias, Machine Learning 45 (1) (2001) 5–32. doi: 10.1023/A:1010933404324.
- [29] Y. Freund, RE Schapire, Uma generalização teórico-decisória da aprendizagem online e uma aplicação ao Boosting, Journal of Computer and System Sciences 55 (1) (1997) 119–139. doi:10.1006/jcss.1997.1504.

- [30] JH Friedman, Aproximação de função gulosa: uma máquina de boosting de gradiente, *Annals of Statistics* 29 (5) (2001) 1189–1232. doi:10.1214/aos/1013203451.
- [31] K. Woods, W. Kegelmeyer, K. Bowyer, Combinação de múltiplos classificadores usando estimativas de precisão local, *IEEE Transactions on Pattern Analysis and Machine Intelligence* 19 (4) (1997) 405–410. doi:10.1109/34.588027.
- [32] G. Giacinto, F. Roli, Seleção dinâmica de classificadores baseada no comportamento de múltiplos classificadores, *Pattern Recognition* 34 (9) (2001) 1879–1881. doi:10.1016/S0031-3203(00)00150-3.
- [33] AS Britto, R. Sabourin, LES Oliveira, Seleção dinâmica de classificadores — Uma revisão abrangente, *Pattern Recognition* 47 (11) (2014) 3665–3680. doi:10.1016/j.patcog.2014.05.003.
- [34] AH Ko, R. Sabourin, AS Britto, Jr., Da seleção dinâmica de classificadores à seleção dinâmica de conjuntos, *Pattern Recognition* 41 (5) (2008) 1718–1731. doi:10.1016/j.patcog.2007.10.015.
- [35] LI Kuncheva, Um estudo teórico sobre seis estratégias de fusão de classificadores, *IEEE Transactions on Pattern Analysis and Machine Intelligence* 24 (2) (2002) 281–286. doi:10.1109/34.982906.
- [36] JS Akosa, Precisão preditiva: uma medida de desempenho enganosa para dados altamente desequilibrados, *SAS Global Forum* 942 (2017) 1–12.
URL <https://support.sas.com/resources/papers/proceedings17/0942-2017.pdf>
- [37] D. Dua, C. Graff, repositório de aprendizado de máquina da UCI (2017).
URL <http://archive.ics.uci.edu/ml>
- [38] P. Virtanen, R. Gommers, TE Oliphant, M. Haberland, T. Reddy, D. Cournapeau, E. Burovski, P. Peterson, W. Weckesser, J. Bright, SJ van der Walt, M. Brett, J. Wilson, KJ Millman, N. Mayorov, ARJ Nelson, E. Jones, R. Kern, E. Larson, CJ Carey, ȳl. Polat, Y. Feng, EW Moore, J. VanderPlas, D. Laxalde, J. Perktold, R. Cimrman, I. Henriksen, EA Quintero, CR Harris, AM Archibald, AH Ribeiro, F. Pe-dregosa, P. van Mulbregt, SciPy 1.0 Contributors, SciPy 1.0: Algoritmos Fundamentais para Computação Científica em Python, *Nature Methods* 17 (2020) 261–272. doi:10.1038/s41592-019-0686-2.
- [39] PR Cavalin, R. Sabourin, CY Suen, Seleção dinâmica de conjuntos de classificadores usando informações contextuais, em: N. El Gayar, J. Kittler, F. Roli (Eds.), *Sistemas de múltiplos classificadores*, Springer Berlin Heidelberg, Berlim, Heidelberg, 2010, pp. 145–154.
- [40] PR Cavalin, R. Sabourin, CY Suen, Abordagens de seleção dinâmica para sistemas de classificação múltipla, *Neural Computing and Applications* 22 (3-4) (2013) 673–688. doi:10.1007/s00521-011-0737-9.

- [41] MA Souza, GD Cavalcanti, RM Cruz, R. Sabourin, Local online geração de pool para seleção dinâmica de classificadores, *Reconhecimento de Padrões* 85 (1) (2019) 132–148. doi:10.1016/j.patcog.2018.08.004.
- [42] RM Cruz, R. Sabourin, GD Cavalcanti, T. Ing Ren, META-DES: A estrutura de seleção de conjunto dinâmico usando meta-aprendizagem, *Pattern Recognition* 48 (5) (2015) 1925–1935. doi:10.1016/j.patcog.2014.12.003.
- [43] RM Cruz, R. Sabourin, GD Cavalcanti, META-DES.H: Uma Dinâmica Técnica de seleção de conjunto usando meta-aprendizagem e uma abordagem de ponderação dinâmica, *Anais da Conferência Internacional Conjunta sobre Redes Neurais 2015-setembro (julho)* (2015). arXiv:1811.01742, doi: 10.1109/IJCNN.2015.7280594.